Projet 3 – Requêtez une base de données avec SQL
Présentation de la méthodologie suivie

Etapes suivies :

1. Découverte des différents types de données dans les deux fichiers CSV

Consultation des deux fichiers CSV afin de comprendre les données :

- Données de contrats clients
- Données du référentiel géographique des régions françaises (extrait du site de data.gouv.fr)

J'ai pris le temps de **comprendre** les différentes données.

J'ai effectué des **filtres** dans les données afin de trouver les différentes valeurs dans Excel.

Incohérences du choix du fichier csv REGIONS :

- des villes de banlieue parisienne sont en doublon
- une même ville peut avoir deux "Code_dep_code_commune"
- problème pour la requête 9 par ex. (surface moyenne des contrats à Paris) : qu'entend-t-on par Paris dans cette requête ?

2. Établissement d'un dictionnaire des données explorées complet

Un **dictionnaire de donnée** se définit comme un **référentiel de métadonnées** qui renseigne sur le contexte d'une base de données et qui fournit les informations nécessaires pour pouvoir l'interpréter.

Cette documentation facilite la **gestion des bases de données** et permet aux administrateurs et utilisateurs de comprendre facilement la structure de leurs bases de données.

Le dictionnaire de données décrit les données qui se trouvent dans une base de données en concentrant **plusieurs types d'informations** :

- Le nom de la table
- Le nom des champs
- La définition des champs
- Type de données
- La longueur (nombre de caractères)
- Les valeurs acceptées
- Les relations et dépendances
- …

En l'espèce, j'ai rempli le dictionnaire des données afin de faire correspondre :

- le nom de chaque colonne entre le dictionnaire des données et les fichiers CSV ;
- les **types de variables** (colonne type de données) et les **contraintes** (taille) que je souhaitai ajouter dans mon modèle de données (exemple : la variable est un nombre alors c'est un INTEGER, la variable ne contient qu'une lettre alors c'est un VARCHAR de contrainte 1, etc.) ;
- la **description des données** pour chaque ligne.

Copie d'écran du dictionnaire de données (fichier excel) :

	Nom des colonnes	Type de données	Taille	Clé	Description
CONTRAT.CSV	Contrat_ID	INT		Clé primaire	Id unique pour les contrats
	No_voie	INT			Numéro dans la voie pour l'adresse du logement assuré
	B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
	Type_de_voie	VARCHAR			Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
	Voie	VARCHAR			Libellé de la voie pour l'adresse du logement assuré
	Code_dep_code_commune	VARCHAR	6	Clé secondaire	Concaténation du code département et code commune pour avoir une clé unique
	Code_postal	INT	5		Code postal pour l'adresse du logement assuré
	Surface	INT	3		surface du logement assuré
	Type_local	VARCHAR			Type de local assuré : appartement ou maison
	Occupation	VARCHAR			Occupant du bien assuré : propriétaire ou locataire
	Type_contrat	VARCHAR			Type de contrat : résidence principale, résidence secondaire ou bien locatif
	Formule	VARCHAR	9		Formule d'assurance choisie : classique ou intégrale
	Valeur_declaree_biens	VARCHAR			Fourchette de la valeur déclarée des biens assurés
	Prix_cotisation_mensuel	INT	3		Prix de la cotisation annuelle d'assurance
REGION.CSV	Code_dep_code_commune	VARCHAR	6	Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
	reg_code	INT	2		Code de la Région
	reg_nom	VARCHAR			Nom de la région
	aca_nom	VARCHAR			Nom de l'académie de rattachement
	dep_nom	VARCHAR			Nom du département
	com_nom_maj_court	VARCHAR			Nom de la commune
	dep_code	VARCHAR	3		Code du département
	dep_nom_num	VARCHAR			Nom et numéro du département

3. Suivi du cours Modélisez vos bases de données

Dans ce cours :

- J'ai découvert tout d'abord le concept de base de données : à quoi ça sert et comment on l'utilise.
- J'ai appris à reconnaître les types de données : celles qui sont très structurées, et celles qui le sont moins.
- J'ai modélisé une base de données en dessinant mon premier diagramme de classes UML.
- J'ai découvert comment traduire mon diagramme UML en un modèle relationnel.

4. Conception d'un Schéma relationnel à l'aide de SQL Power Architect

A la suite du cours j'ai utilisé le logiciel **SQL Power Architect** afin de concevoir le schéma relationnel pour le projet

Je suis parti de l'ébauche du **schéma relationnel normalisé** fait avec SQL Power Architects et j'ai fait **correspondre** le schéma relationnel avec le dictionnaire des données directement dans le logiciel, en :

- Ajoutant les **colonnes manquantes.**
- Modifiant les **types de données.**
- Ajoutant les **contraintes.**

Copie d'écran du schéma relationnel conçu :

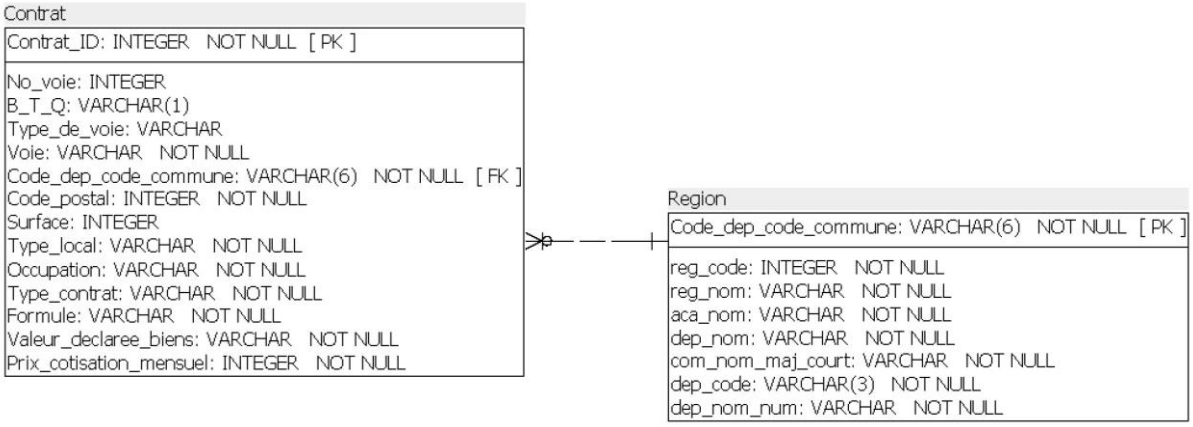

5. Création du code SQL générant les tables dans la base de données (pour le SGBDR SQLite)

Le logiciel Power Architect permet de générer un code pour différents SGBD.

Toutefois il ne propose pas de le faire pour le logiciel SQLite que j'avais choisi d'utiliser (dans la mesure où il s'agissait du SGBDR utilisé dans le cours suivant : **Requêtez une base de données avec SQL**).

En conséquence j'ai dû générer un code pour le logiciel MySQL et le modifier afin qu'il soit adapté pour être utilisé dans SQLite :

```sql
CREATE TABLE Region (
    Code_dep_code_commune TEXT NOT NULL,
    reg_code INTEGER NOT NULL,
    reg_nom TEXT NOT NULL,
    aca_nom TEXT NOT NULL,
    dep_nom TEXT NOT NULL,
    com_nom_maj_court TEXT NOT NULL,
    dep_code TEXT NOT NULL,
    dep_nom_num TEXT NOT NULL,
    PRIMARY KEY (Code_dep_code_commune)
);

CREATE TABLE Contrat (
    Contrat_ID INTEGER NOT NULL,
    No_voie INTEGER,
    B_T_Q TEXT,
    Type_de_voie TEXT,
    Voie TEXT,
    Code_dep_code_commune TEXT NOT NULL,
    Code_postal INTEGER NOT NULL,
    Surface INTEGER,
    Type_local TEXT NOT NULL,
    Occupation TEXT NOT NULL,
    Type_contrat TEXT NOT NULL,
    Formule TEXT NOT NULL,
    Valeur_declaree_biens TEXT NOT NULL,
    Prix_cotisation_mensuel INTEGER NOT NULL,
    PRIMARY KEY (Contrat_ID),
    FOREIGN KEY (Code_dep_code_commune)
        REFERENCES Region (Code_dep_code_commune)
        ON DELETE NO ACTION
        ON UPDATE NO ACTION
);
```

J'ai Installé le logiciel **SQLite** et effectué les paramétrages nécessaires.

J'ai créé mes tables dans la base de données grâce au code SQL :

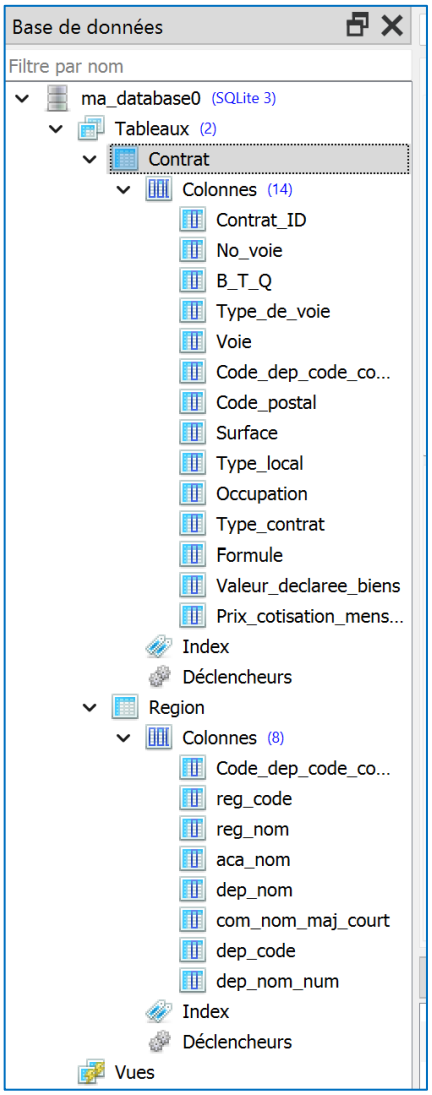

6. Chargement des données dans la base de données créée

J'ai chargé toutes les données des deux fichiers dans le système de gestion de base de données (SGBD). Le nettoyage et le formatage des données sont effectués.

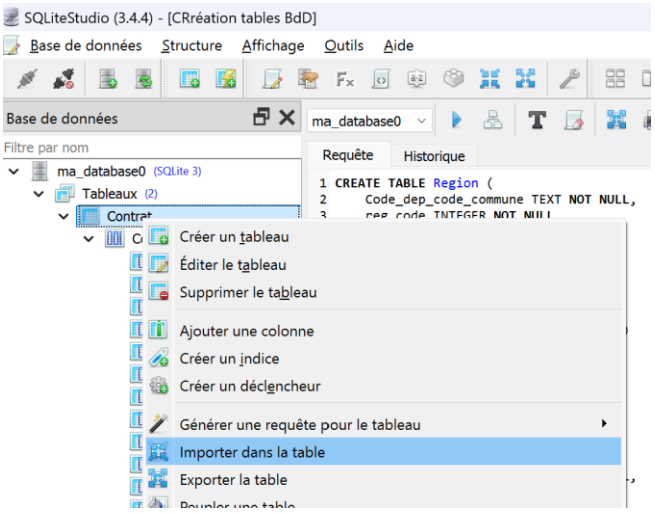

Création de la table **CONTRAT :**

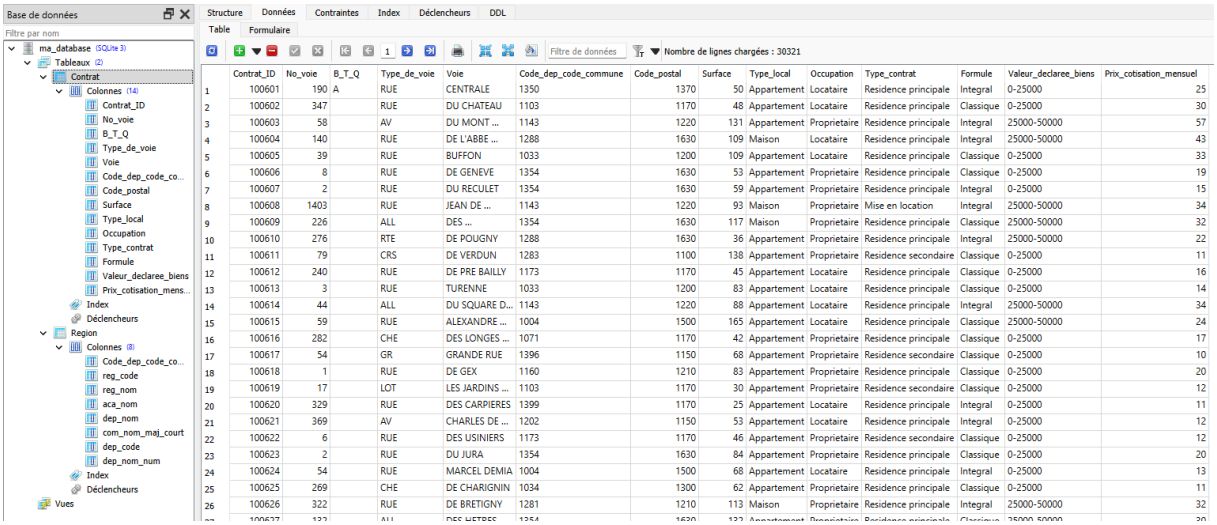

	Contrat_ID	No_voie	B_T_Q	Type_de_voie	Voie	Code_dep_code_commune	Code_postal	Surface	Type_local	Occupation	Type_contrat	Formule	Valeur_declaree_biens	Prix_cotisation_mensuel
1	100601	190	A	RUE	CENTRALE	1350	1370	50	Appartement	Locataire	Residence principale	Integral	0-25000	25
2	100602	347		RUE	DU CHATEAU	1103	1170	48	Appartement	Locataire	Residence principale	Classique	0-25000	30
3	100603	58		AV	DU MONT ...	1143	1220	131	Appartement	Proprietaire	Residence principale	Integral	25000-50000	57
4	100604	140		RUE	DE L'ABBE ...	1288	1630	109	Maison	Locataire	Residence principale	Integral	25000-50000	43
5	100605	39		RUE	BUFFON	1033	1200	109	Appartement	Locataire	Residence principale	Classique	0-25000	33
6	100606	8		RUE	DE GENEVE	1354	1630	53	Appartement	Proprietaire	Residence principale	Classique	0-25000	19
7	100607	2		RUE	DU RECULET	1354	1630	59	Appartement	Proprietaire	Residence principale	Integral	0-25000	15
8	100608	1403		RUE	JEAN DE ...	1143	1220	93	Maison	Proprietaire	Mise en location	Integral	25000-50000	34
9	100609	226		ALL	DES ...	1354	1630	117	Maison	Proprietaire	Residence principale	Classique	25000-50000	32
10	100610	276		RTE	DE POUGNY	1288	1630	36	Appartement	Proprietaire	Residence principale	Integral	25000-50000	22
11	100611	79		CRS	DE VERDUN	1283	1100	138	Appartement	Proprietaire	Residence secondaire	Classique	0-25000	11
12	100612	240		RUE	DE PRE BAILLY	1173	1170	45	Appartement	Locataire	Residence principale	Classique	0-25000	16
13	100613	3		RUE	TURENNE	1033	1200	83	Appartement	Locataire	Residence principale	Classique	0-25000	14
14	100614	44		ALL	DU SQUARE D...	1143	1220	88	Appartement	Locataire	Residence principale	Integral	25000-50000	34
15	100615	59		RUE	ALEXANDRE ...	1004	1500	165	Appartement	Locataire	Residence principale	Classique	25000-50000	24
16	100616	282		CHE	DES LONGES ...	1071	1170	42	Appartement	Proprietaire	Residence principale	Classique	0-25000	17
17	100617	54		GR	GRANDE RUE	1396	1150	68	Appartement	Proprietaire	Residence secondaire	Classique	0-25000	10
18	100618	1		RUE	DE GEX	1160	1210	83	Appartement	Proprietaire	Residence principale	Classique	0-25000	20
19	100619	17		LOT	LES JARDINS ...	1103	1170	30	Appartement	Proprietaire	Residence secondaire	Classique	0-25000	12
20	100620	329		RUE	DES CARPIERES	1399	1170	25	Appartement	Locataire	Residence principale	Integral	0-25000	11
21	100621	369		AV	CHARLES DE ...	1202	1150	53	Appartement	Locataire	Residence principale	Integral	0-25000	12
22	100622	6		RUE	DES USINIERS	1173	1170	46	Appartement	Proprietaire	Residence secondaire	Classique	0-25000	12
23	100623	2		RUE	DU JURA	1354	1630	84	Appartement	Proprietaire	Residence principale	Classique	0-25000	20
24	100624	54		RUE	MARCEL DEMIA	1004	1500	68	Appartement	Locataire	Residence principale	Integral	0-25000	13
25	100625	269		CHE	DE CHARIGNIN	1034	1300	62	Appartement	Proprietaire	Residence principale	Classique	0-25000	11
26	100626	322		RUE	DE BRETIGNY	1281	1210	113	Maison	Proprietaire	Residence principale	Integral	25000-50000	32

Création de la Table **REGION** :

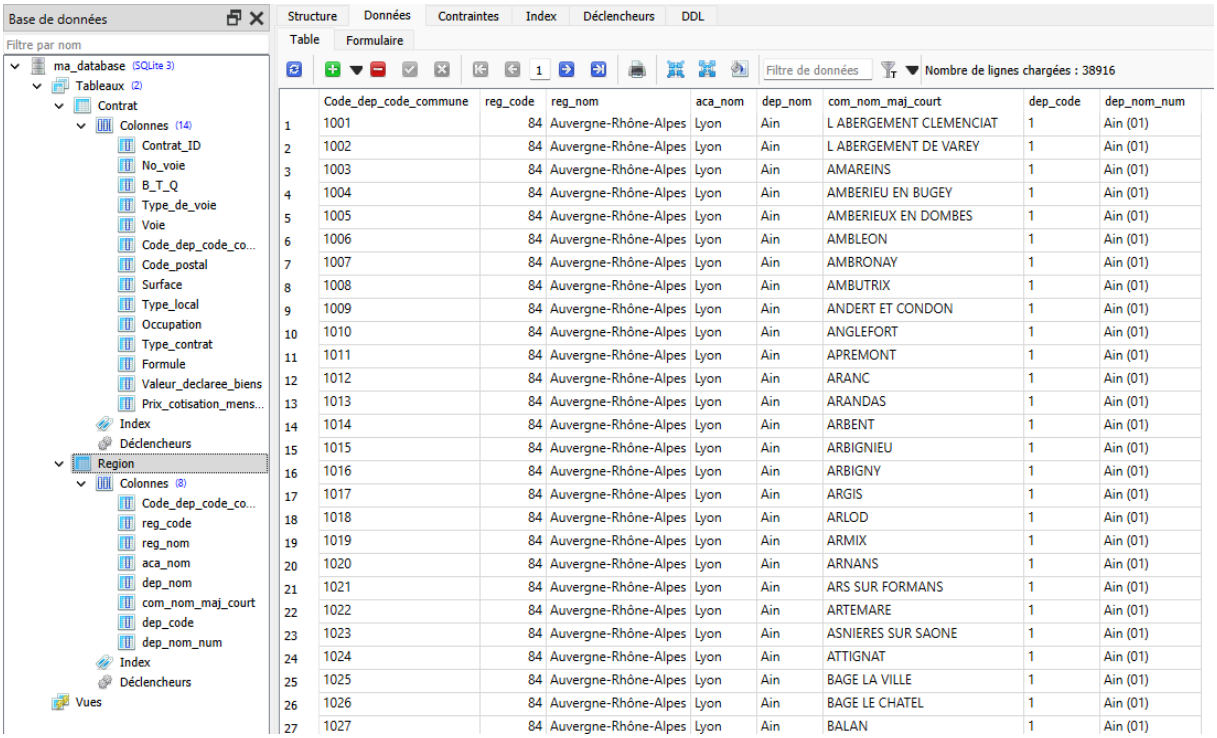

	Code_dep_code_commune	reg_code	reg_nom	aca_nom	dep_nom	com_nom_maj_court	dep_code	dep_nom_num
1	1001	84	Auvergne-Rhône-Alpes	Lyon	Ain	L ABERGEMENT CLEMENCIAT	1	Ain (01)
2	1002	84	Auvergne-Rhône-Alpes	Lyon	Ain	L ABERGEMENT DE VAREY	1	Ain (01)
3	1003	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMAREINS	1	Ain (01)
4	1004	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBERIEU EN BUGEY	1	Ain (01)
5	1005	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBERIEUX EN DOMBES	1	Ain (01)
6	1006	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBLEON	1	Ain (01)
7	1007	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBRONAY	1	Ain (01)
8	1008	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBUTRIX	1	Ain (01)
9	1009	84	Auvergne-Rhône-Alpes	Lyon	Ain	ANDERT ET CONDON	1	Ain (01)
10	1010	84	Auvergne-Rhône-Alpes	Lyon	Ain	ANGLEFORT	1	Ain (01)
11	1011	84	Auvergne-Rhône-Alpes	Lyon	Ain	APREMONT	1	Ain (01)
12	1012	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARANC	1	Ain (01)
13	1013	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARANDAS	1	Ain (01)
14	1014	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARBENT	1	Ain (01)
15	1015	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARBIGNIEU	1	Ain (01)
16	1016	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARBIGNY	1	Ain (01)
17	1017	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARGIS	1	Ain (01)
18	1018	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARLOD	1	Ain (01)
19	1019	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARMIX	1	Ain (01)
20	1020	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARNANS	1	Ain (01)
21	1021	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARS SUR FORMANS	1	Ain (01)
22	1022	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARTEMARE	1	Ain (01)
23	1023	84	Auvergne-Rhône-Alpes	Lyon	Ain	ASNIERES SUR SAONE	1	Ain (01)
24	1024	84	Auvergne-Rhône-Alpes	Lyon	Ain	ATTIGNAT	1	Ain (01)
25	1025	84	Auvergne-Rhône-Alpes	Lyon	Ain	BAGE LA VILLE	1	Ain (01)
26	1026	84	Auvergne-Rhône-Alpes	Lyon	Ain	BAGE LE CHATEL	1	Ain (01)
27	1027	84	Auvergne-Rhône-Alpes	Lyon	Ain	BALAN	1	Ain (01)

Vérifiez qu'il y a **le bon nombre de lignes** entre le fichier CSV et le chargement dans la base de données :

- table région : **38.916 lignes OK**

- table contrat : **30.321 lignes au lieu de 30.335 NOK**
  - problème : le code ne fonctionne pas totalement, je n'ai pas pu charger toutes les lignes du fichier CSV Contrats (30.321 lignes au lieu de 30.335)
  - j'ai essayé de le faire via MySQL : même souci (30.204 lignes au lieu de 30.335)
  - j'ai remarqué que certains "Code_dep_code_commune" de la table CONTRATS n'existaient pas dans la table REGIONS : 9 lignes a priori
    - ✓ ex : 97460, 97434, 97470
    - ✓ à chaque fois ils sont similaires au code postal (ce qui n'est a priori pas le cas ailleurs), et se trouvent sur l'île de la réunion.
    - ✓ plus éventuellement la problématique soulevée sur les doublons de Communes (étape n° 1).

7. Suivi du cours Requêtez une base de données avec SQL

Ce cours m'a permis de m'initier à la modélisation relationnelle à travers des cas concrets.

Ensuite, cela m'a permis à effectuer des requêtes SQL pour explorer des bases de données et extraire des informations spécifiques.

Pour finir, j'ai appris à appliquer des fonctions à mes requêtes SQL pour affiner mes recherches.

Voici une liste des principales fonctions et mots-clés utilisés dans SQLite avec des explications :

Commandes de définition de données (DDL)

1. **CREATE TABLE**
   - **Syntaxe** : CREATE TABLE table_name (column1 datatype PRIMARY KEY, column2 datatype, ...);
   - **Description** : Crée une nouvelle table dans la base de données.
   - **Exemple** :

```
CREATE TABLE Region (
   Code_dep_code_commune TEXT PRIMARY KEY,
   reg_code INTEGER,
   reg_nom TEXT
);
```

Commandes de manipulation de données (DML)

1. **SELECT**
   - **Syntaxe** : SELECT column1, column2, ... FROM table_name WHERE condition;
   - **Description** : Sélectionne des données dans une table.
   - **Exemple** :

```
SELECT reg_nom
FROM Region
WHERE reg_code = 1;
```

Commandes de requête :

1. **WHERE**
   - **Syntaxe** : SELECT column1, column2, ... FROM table_name WHERE condition;

- **Description** : Filtre les résultats pour ne retourner que ceux qui satisfont la condition spécifiée.
- **Exemple** :

```
SELECT reg_nom
FROM Region
WHERE reg_code = 1;
```

2. **GROUP BY**
   - **Syntaxe :** SELECT column1, COUNT(column2) FROM table_name GROUP BY column1;
   - **Description** : Regroupe les lignes ayant les mêmes valeurs dans des colonnes spécifiées en groupes d'agrégat.
   - Exemple :

```
SELECT reg_nom, COUNT(*) FROM Region GROUP BY reg_nom;
```

3. **ORDER BY**
   - **Syntaxe :** SELECT column1, column2, ... FROM table_name ORDER BY column1 [ASC|DESC];
   - **Description :** Trie les résultats par une ou plusieurs colonnes.
   - **Exemple :**

```
SELECT reg_nom
FROM Region
ORDER BY reg_nom DESC;
```

4. **HAVING**
   - **Syntaxe** : SELECT column1, COUNT(column2) FROM table_name GROUP BY column1 HAVING COUNT(column2) > value;
   - **Description** : Filtre les groupes après l'application de la clause GROUP BY.
   - **Exemple** :

```
SELECT reg_nom, COUNT(*)
FROM Region
GROUP BY reg_nom
HAVING COUNT(*) > 1;
```

5. **JOIN ... ON**
   - **Syntaxe** : SELECT columns FROM table1 JOIN table2 ON table1.column = table2.column;
   - **Description** : Combine les lignes de deux tables ou plus, basées sur une condition commune.
   - **Exemple** :

```
SELECT Contrat.Contrat_ID, Region.reg_nom
FROM Contrat
JOIN Region ON Contrat.Code_dep_code_commune =
Region.Code_dep_code_commune;
```

Fonctions d'agrégation :

1. **AVG**
   - **Syntaxe :** SELECT AVG(column) FROM table_name;
   - **Description :** Calcule la moyenne des valeurs d'une colonne numérique.
   - **Exemple :**

```
SELECT AVG(Surface)
FROM Contrat;
```

2. **COUNT**
   - **Syntaxe** : SELECT COUNT(column) FROM table_name;
   - **Description** : Compte le nombre de valeurs (non NULL) dans une colonne.
   - **Exemple**

```
SELECT COUNT(Contrat_ID)
FROM Contrat;
```

3. **MAX**
   - **Syntaxe :** SELECT MAX(column) FROM table_name;
   - **Description :** Renvoie la valeur maximale d'une colonne.
   - **Exemple** :

```
SELECT MAX(Surface)
FROM Contrat;
```

4. **MIN**
   - **Syntaxe** : SELECT MIN(column) FROM table_name;
   - **Description** : Renvoie la valeur minimale d'une colonne.
   - **Exemple** :

```
SELECT MIN(Surface)
FROM Contrat;
```

5. **SUM**
   - **Syntaxe** : SELECT SUM(column) FROM table_name;
   - **Description** : Calcule la somme des valeurs d'une colonne numérique.
   - **Exemple** :

```
SELECT SUM(Prix_cotisation_mensuel)
FROM Contrat;
```

Fonctions de chaîne

1. **LOWER**
   - **Syntaxe** : SELECT LOWER(column) FROM table_name;
   - **Description** : Convertit toutes les lettres d'une chaîne en minuscules.
   - **Exemple** :

```
SELECT LOWER(nom)
FROM Region;
```

2. **UPPER**
   - **Syntaxe** : SELECT UPPER(column) FROM table_name;
   - **Description** : Convertit toutes les lettres d'une chaîne en majuscules.
   - **Exemple** :

```
SELECT UPPER(nom)
FROM Region;
```

8. Analyses menées à l'aide de requêtes SQL

Grace au cours **Requêtez une base de données avec SQL** j'ai pu mener à bien différentes analyses dans la base de données grâce à des requêtes SQL.

Le but de ces analyses est de m'**initier** au langage SQL. Elles doivent vous permettre d'en **construire la logique**. Pour cela :

- J'ai suivi le cours fourni **Requêtez une base de données avec SQL**;
- Je me suis assuré de lire attentivement l'exemple fourni dans le tableau ;
- J'ai pris le temps de construire ma réflexion sur la rédaction de mes premières requêtes **en identifiant d'abord de quelles variables j'avais besoin** ;
- J'ai verbalisé et **expliqué mon cheminement logique** en détail à mon mentor de façon à ce qu'il puisse détecter une éventuelle compréhension erronée ou une lacune

L'ensemble des requêtes complétées figurent dans le document word « ***Maganto_Laurent_2_liste_082024*** », avec pour chaque requête :

- le code SQL associé ;
- la copie d'écran des résultats ;
- et des explications détaillées.