PROJET DATAImmo

Création et utilisation de la base de données

Laurent MAGANTO

Laplace Immo

Contexte du projet

Laplace Immo

RÉSEAU NATIONAL
D'AGENCES IMMOBILIÈRES

Projet "DATAImmo" :

- ► création d'un modèle pour mieux prévoir le prix de vente des biens immobiliers.

STEP 2

Deux étapes :

1. modification de la base de données permettant de collecter les transactions immobilières et foncières en France.
2. Utilisation de cette base pour analyser le marché et aider les différentes agences régionales à mieux accompagner leurs clients.

Les données initiales

Excel

3 fichiers Excel à disposition :

Valeurs-foncières

Données extraites du site **open data** des Demandes de valeurs foncières (DVF)

fr-esr-referentiel-geographique

données de **data.gouv** sur les régions, avec le référentiel géographique français, communes, unités urbaines, aires urbaines, départements, académies, régions

donnees_communes

Données de l'**INSEE** avec les résultats des recensements de la population

La stratégie de sauvegarde et la conformité RGPD

STRATÉGIE DE SAUVEGARDE

- Mise en place de mesures pour assurer la sécurité des données en cas de problème (en effectuant des sauvegardes régulières sur des serveurs distants, en utilisant des solutions de stockage cloud à des endroits différents).
- La restauration des données a été testée à partir de ces sauvegardes afin de s’assurer que tout fonctionne correctement.

CONFORMITÉ RGPD

- Suppression de la colonne « Nom de l'acquéreur » (comportant des données personnelles) présent dans le fichier « Valeurs-foncières »
- Ces données personnelles n’ont pas été stockées dans la Base de données définitive.

L'extrait du dictionnaire des données

DICTIONNAIRE DES DONNÉES - Référentiel géographique

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
REG_NOM	Libellé de la région	Varchar		Élémentaire		
REG_CODE	Code de la Région	Integer	2	Élémentaire		
DEP_CODE	Code département	Varchar	3	Élémentaire		
DEP_NOM	Libellé du département	Varchar		Élémentaire		
COM_CODE	code commune (équivalent à la concaténation du code Dep et du Code Com de la table Commune)	Varchar	6	Élémentaire		

DICTIONNAIRE DES DONNÉES - Données communes

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
id_codedep_codecommune (PK)	**Concaténation de deux variables (Code département et Code commune)**	**Varchar**	**6**	**Concaténer**	**Ne doit pas être nul**	**concaténer les colonnes CODDEP et CODCOM**
CODREG (FK)	Code de la Région	Integer	2	Elémentaire	Ne doit pas être nul	
CODDEP	Code du Département	Varchar	3	Elémentaire	Ne doit pas être nul	
CODCOM	Code de la Commune	Integer	3	Elémentaire	Ne doit pas être nul	
COM	Nom d'une commune	Varchar		Elémentaire	Ne doit pas être nul - convertir au même que dans la colonne "com_nom_maj" de la table référentiel géographique ?	
PTOT	population totale : somme de la population municipale et de la population comptée à part	Integer	6	Élémentaire		

Le schéma relationnel normalisé

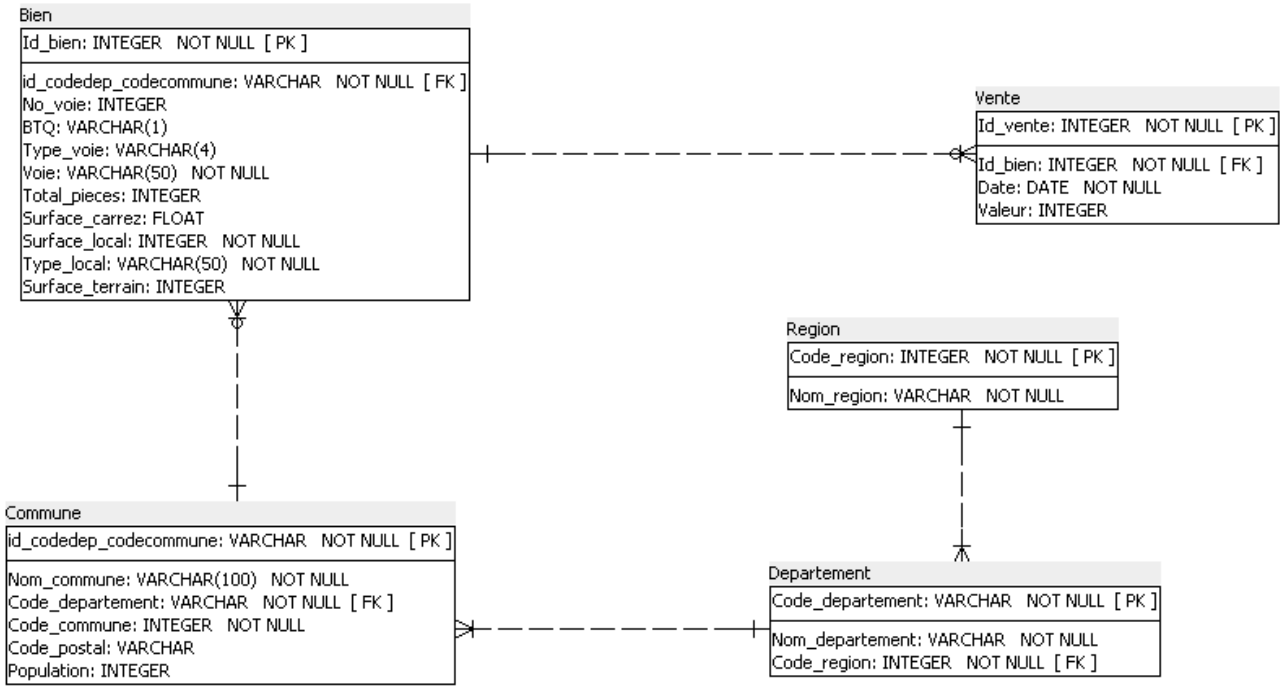

La base de données avec les tables créées et les données chargées

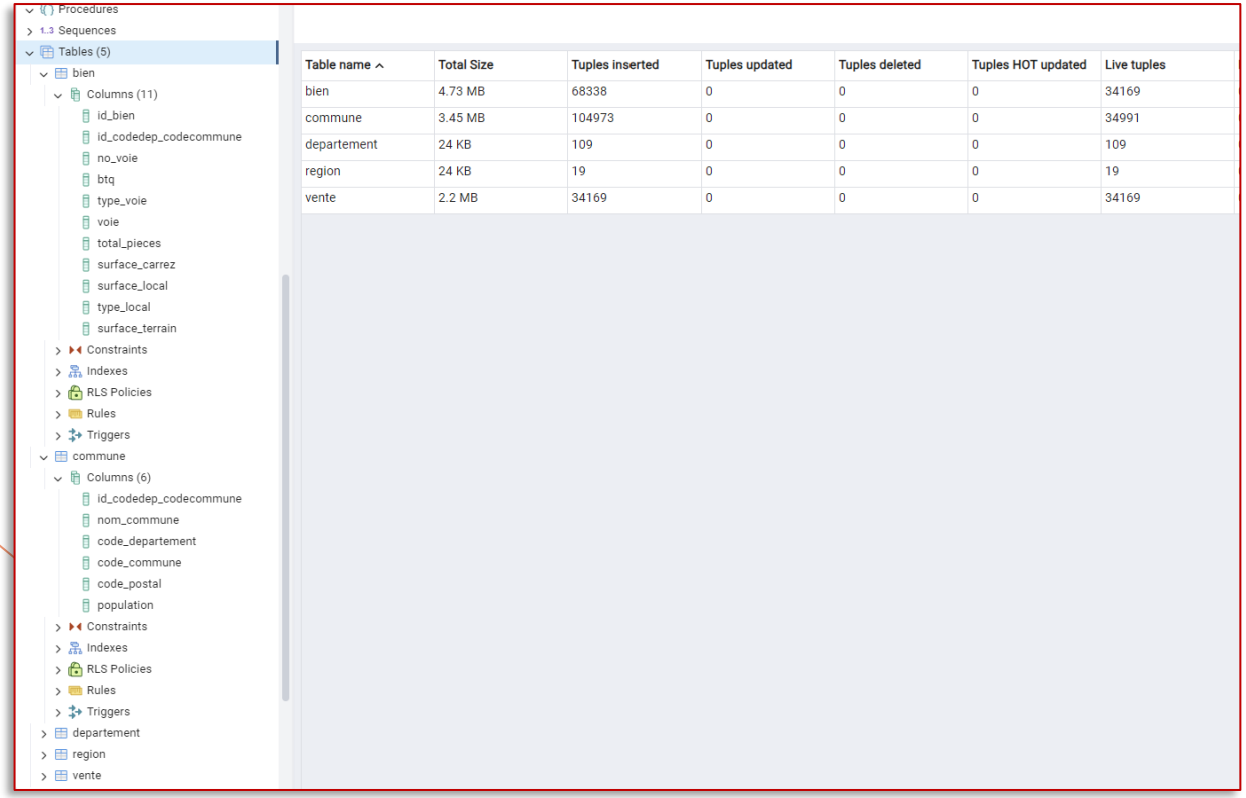

Table name	Total Size	Tuples inserted	Tuples updated	Tuples deleted	Tuples HOT updated	Live tuples
bien	4.73 MB	68338	0	0	0	34169
commune	3.45 MB	104973	0	0	0	34991
departement	24 KB	109	0	0	0	109
region	24 KB	19	0	0	0	19
vente	2.2 MB	34169	0	0	0	34169

Les requêtes et screenshots qui permettent de démontrer le bon chargement des données

```sql
SELECT COUNT(*) AS "Nombre de lignes dans Region" FROM region;
```

	Nombre de lignes dans Region bigint
1	19

```sql
SELECT COUNT(*) AS "Nombre de lignes dans Departement" FROM departement;
```

	Nombre de lignes dans Departement bigint
1	109

```sql
SELECT COUNT(*) AS "Nombre de lignes dans Commune" FROM commune;
```

	Nombre de lignes dans Commune bigint
1	34991

```sql
SELECT COUNT(*) AS "Nombre de lignes dans Bien" FROM bien;
```

	Nombre de lignes dans Bien bigint
1	34169

```sql
SELECT COUNT(*) AS "Nombre de lignes dans Vente" FROM vente;
```

	Nombre de lignes dans Vente bigint
1	34169

Requêtes SQL et résultats

Requête 1

Nombre total d'appartements vendus au 1er semestre 2020

	Nombre d'appartements vendus au 1er semestre 2020 bigint
1	31378

```sql
SELECT
  count(vente.id_vente) AS "Nombre d'appartements vendus au 1er semestre 2020"
FROM
  bien
  JOIN vente ON vente.id_bien = Bien.id_bien
WHERE
  bien.type_local = 'Appartement'
  AND vente.date BETWEEN '2020-01-01'
  AND '2020-06-30';
```

Requête 2

Nombre de ventes d'appartement par région pour le 1er semestre 2020

	Région character varying (100)	Nombre de ventes d'appartements (1er semestre 2020) bigint
1	Ile-de-France	13995
2	Provence-Alpes-Côte d'Azur	3649
3	Auvergne-Rhône-Alpes	3253
4	Nouvelle-Aquitaine	1932
5	Occitanie	1640
6	Pays de la Loire	1357
7	Hauts-de-France	1254
8	Grand Est	984
9	Bretagne	983
10	Normandie	862
11	Centre-Val de Loire	696
12	Bourgogne-Franche-Comté	376
13	Corse	223
14	Martinique	94
15	La Réunion	44
16	Guyane	34
17	Guadeloupe	2

```sql
SELECT
  region.nom_region AS "Région",
  COUNT (vente.id_vente) AS "Nombre de ventes d'appartements (1er semestre 2020)"
FROM
  region
  JOIN departement ON region.code_region = departement.code_region
  JOIN commune ON departement.code_departement = commune.code_departement
  JOIN bien ON commune.id_codedep_codecommune = bien.id_codedep_codecommune
  JOIN vente ON vente.id_bien = bien.id_bien
WHERE
  bien.type_local = 'Appartement'
  AND vente.date BETWEEN '2020-01-01'
  AND '2020-06-30'
GROUP BY
  region.nom_region
order by
  "Nombre de ventes d'appartements (1er semestre 2020)" DESC
```

Requête 3

Proportion des ventes d'appartements par le nombre de pièces

	Nombre de pièces integer	Nombre de ventes d'appartements (1er semestre 2020) bigint	Proportion (%) numeric
1	2	9783	31.18
2	3	8966	28.57
3	1	6739	21.48
4	4	4460	14.21
5	5	1114	3.55
6	6	204	0.65
7	7	54	0.17
8	0	30	0.10
9	8	17	0.05
10	9	8	0.03
11	10	2	0.01
12	11	1	0.00

```sql
SELECT
  bien.total_pieces AS "Nombre de pièces",
  COUNT(vente.id_vente) AS "Nombre de ventes d'appartements (1er semestre 2020)",
  ROUND(
    100.0 * COUNT(vente.id_vente) / total.total_ventes,
    2
  ) AS "Proportion (%)"
FROM
  bien
  JOIN vente ON vente.id_bien = bien.id_bien
  JOIN (
    SELECT
      COUNT(id_vente) AS total_ventes
    FROM
      vente
      JOIN bien ON vente.id_bien = bien.id_bien
    WHERE
      bien.type_local = 'Appartement'
  ) AS total ON true
WHERE
  bien.type_local = 'Appartement'
GROUP BY
  bien.total_pieces,
  total.total_ventes
ORDER BY
  "Proportion (%)" DESC;
```

Requête 4

Liste des 10 départements où le prix du mètre carré est le plus élevé

	Département character varying (100)	Prix moyen au m² (en €) numeric
1	Paris	12045.35
2	Hauts-de-Seine	7219.39
3	Val-de-Marne	5340.51
4	Alpes-Maritimes	4696.76
5	Haute-Savoie	4667.13
6	Seine-Saint-Denis	4336.70
7	Yvelines	4225.25
8	Rhône	4059.28
9	Corse-du-Sud	4010.60
10	Gironde	3764.14

```sql
SELECT
  departement.nom_departement AS "Département",
  ROUND(
    CAST(
      AVG(
        vente.valeur / bien.surface_carrez
      ) AS numeric
    ),
    2
  ) AS "Prix moyen au m² (en €)"
FROM
  departement
  JOIN commune ON departement.code_departement = commune.code_departement
  JOIN bien ON commune.id_codedep_codecommune = bien.id_codedep_codecommune
  JOIN vente ON vente.id_bien = bien.id_bien
WHERE
  bien.surface_carrez > 0 -- Filtre pour éviter les divisions par zéro
GROUP BY
  departement.nom_departement
ORDER BY
  "Prix moyen au m² (en €)" DESC
LIMIT
  10;
```

Requête 5

Prix moyen du mètre carré d'une maison en Île-de-France

	Région character varying (100)	Prix moyen d'une maison au m² (en €) numeric
1	Ile-de-France	3745.09

```sql
SELECT
  region.nom_region AS "Région",
  ROUND(
    CAST(
      AVG(
        vente.valeur / bien.surface_carrez
      ) AS numeric
    ),
    2
  ) AS "Prix moyen d'une maison au m² (en €)"
FROM
  region
  JOIN departement ON region.code_region = departement.code_region
  JOIN commune ON departement.code_departement = commune.code_departement
  JOIN bien ON commune.id_codedep_codecommune = bien.id_codedep_codecommune
  JOIN vente ON vente.id_bien = bien.id_bien
WHERE
  bien.type_local = 'Maison'
  AND region.nom_region = 'Ile-de-France'
  AND bien.surface_carrez > 0 -- évite les divisions par zéro
GROUP BY
  region.nom_region
```

Requête 6

Liste des 10 appartements les plus chers avec la région et le nombre de mètres carrés

	N° appartement integer	Prix integer	Région character varying (100)	nombre de m² real
1	19411	9000000	Ile-de-France	9.1
2	26876	8600000	Ile-de-France	64
3	16946	8577713	Ile-de-France	20.55
4	19573	7620000	Ile-de-France	42.77
5	16842	7600000	Ile-de-France	253.3
6	16215	7535000	Ile-de-France	139.9
7	19074	7420000	Ile-de-France	360.95
8	19231	7200000	Ile-de-France	595
9	16184	7050000	Ile-de-France	122.56
10	16220	6600000	Ile-de-France	79.38

```sql
SELECT
  bien.id_bien AS "N° appartement",
  vente.valeur AS "Prix",
  region.nom_region AS "Région",
  bien.surface_carrez AS "nombre de m²"
FROM
  region
  JOIN departement ON region.code_region = departement.code_region
  JOIN commune ON departement.code_departement = commune.code_departement
  JOIN bien ON commune.id_codedep_codecommune = bien.id_codedep_codecommune
  JOIN vente ON vente.id_bien = bien.id_bien
WHERE
  bien.type_local = 'Appartement'
ORDER BY
  "Prix" DESC
LIMIT
  10
```

Requête 7

Taux d'évolution du nombre de ventes entre le premier et le second trimestre de 2020

	Nombre de ventes en T1 bigint	Nombre de ventes en T2 bigint	Taux d'évolution des ventes (en %) numeric
1	16776	17393	3.68

```sql
WITH venteT1 AS (
    -- Sous-requête pour le nombre de ventes au 1er trimestre 2020
    SELECT COUNT(id_vente) AS totalventeT1
    FROM vente
    WHERE date BETWEEN '2020-01-01' AND '2020-03-31'
),
venteT2 AS (
    -- Sous-requête pour le nombre de ventes au 2ème trimestre 2020
    SELECT COUNT(id_vente) AS totalventeT2
    FROM vente
    WHERE date BETWEEN '2020-04-01' AND '2020-06-30'
)

SELECT
    venteT1.totalventeT1 AS "Nombre de ventes en T1",
    venteT2.totalventeT2 AS "Nombre de ventes en T2",
    ROUND(CAST((venteT2.totalventeT2 - venteT1.totalventeT1) AS numeric) /
          CAST(venteT1.totalventeT1 AS numeric) * 100, 2) AS "Taux d'évolution des ventes (en %)"
FROM
    venteT1,
    venteT2;
```

Requête 8

Classement des régions par rapport au prix au mètre carré des appartements de plus de 4 pièces

	Région character varying (100)	Prix moyen au m² (appartements > 4 pièces) numeric
1	Ile-de-France	8757.64
2	La Réunion	3641.81
3	Provence-Alpes-Côte d'Azur	3587.65
4	Corse	3104.88
5	Auvergne-Rhône-Alpes	2891.38
6	Nouvelle-Aquitaine	2465.48
7	Bretagne	2412.05
8	Pays de la Loire	2315.76
9	Hauts-de-France	2189.93
10	Occitanie	2097.23
11	Normandie	2015.77
12	Grand Est	1540.89
13	Centre-Val de Loire	1453.11
14	Bourgogne-Franche-Comté	1251.19
15	Martinique	573.48

```sql
SELECT
  region.nom_region AS "Région",
  ROUND(
    CAST(
      AVG(
        vente.valeur / bien.surface_carrez
      ) AS numeric
    ),
    2
  ) AS "Prix moyen au m² (appartements > 4 pièces)"
FROM
  region
  JOIN departement ON region.code_region = departement.code_region
  JOIN commune ON departement.code_departement = commune.code_departement
  JOIN bien ON commune.id_codedep_codecommune = bien.id_codedep_codecommune
  JOIN vente ON vente.id_bien = bien.id_bien
WHERE
  bien.total_pieces > 4
  AND bien.type_local = 'Appartement'
GROUP BY
  region.nom_region
ORDER BY
  "Prix moyen au m² (appartements > 4 pièces)" DESC;
```

Requête 9

Liste des communes ayant eu au moins 50 ventes au 1er trimestre 2020

	Commune character varying (100)	Nombre de ventes (T1 2020) bigint
1	Paris 17e Arrondissement	228
2	Paris 15e Arrondissement	215
3	Paris 18e Arrondissement	209
4	Nice	173
5	Paris 11e Arrondissement	169
6	Paris 16e Arrondissement	165
7	Bordeaux	157
8	Paris 14e Arrondissement	146
9	Paris 20e Arrondissement	127
10	Nantes	119
11	Paris 19e Arrondissement	116
12	Paris 12e Arrondissement	110
13	Paris 10e Arrondissement	109
14	Paris 9e Arrondissement	106
15	Grenoble	106
16	Boulogne-Billancourt	99
17	Paris 13e Arrondissement	94
18	Paris 7e Arrondissement	87

```sql
SELECT
  commune.nom_commune AS "Commune",
  COUNT(vente.id_vente) AS "Nombre de ventes (T1 2020)"
FROM
  commune
  JOIN bien ON commune.id_codedep_codecommune = bien.id_codedep_codecommune
  JOIN vente ON vente.id_bien = bien.id_bien
WHERE
  vente.date BETWEEN '2020-01-01'
  AND '2020-03-31'
GROUP BY
  commune.nom_commune
HAVING
  COUNT(vente.id_vente) >= 50
ORDER BY
  "Nombre de ventes (T1 2020)" DESC;
```

Requête 10

Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces

	Différence absolue (€) au m² numeric	Différence en % numeric
1	-603.67	-12.31

```
WITH Prix2pieces AS (
    -- Sous-requête pour le prix moyen au m² des appartements de 2 pièces
    SELECT AVG(vente.valeur / bien.surface_carrez) AS Appart2pieces_prix
    FROM vente
    JOIN bien ON vente.id_bien = bien.id_bien
    WHERE bien.type_local = 'Appartement'
      AND bien.total_pieces = 2
),
Prix3pieces AS (
    -- Sous-requête pour le prix moyen au m² des appartements de 3 pièces
    SELECT AVG(vente.valeur / bien.surface_carrez) AS Appart3pieces_prix
    FROM vente
    JOIN bien ON vente.id_bien = bien.id_bien
    WHERE bien.type_local = 'Appartement'
      AND bien.total_pieces = 3
)

SELECT
    ROUND(CAST(Prix3pieces.Appart3pieces_prix - Prix2pieces.Appart2pieces_prix AS numeric), 2) AS "Différence absolue
(€) au m²",
    ROUND(CAST((Prix3pieces.Appart3pieces_prix - Prix2pieces.Appart2pieces_prix) / Prix2pieces.Appart2pieces_prix AS
numeric) * 100, 2) AS "Différence en %"
FROM
    Prix2pieces,
    Prix3pieces;
```

Requête 11

Moyennes de valeurs foncières pour le top 3 des communes des départements 6, 13, 33, 59 et 69

	Commune character varying (100)	Code Département character varying (10)	Nom Département character varying (100)	Moyenne de la valeur foncière numeric
1	Saint-Jean-Cap-Ferrat	06	Alpes-Maritimes	968750.00
2	Eze	06	Alpes-Maritimes	655000.00
3	Mouans-Sartoux	06	Alpes-Maritimes	476898.13
4	Gignac-la-Nerthe	13	Bouches-du-Rhône	330000.00
5	Saint-Savournin	13	Bouches-du-Rhône	314425.00
6	Cassis	13	Bouches-du-Rhône	313416.88
7	Lège-Cap-Ferret	33	Gironde	549500.64
8	Vayres	33	Gironde	335000.00
9	Arcachon	33	Gironde	307435.93
10	Bersée	59	Nord	433202.00
11	Cysoing	59	Nord	408550.00
12	Halluin	59	Nord	322250.00
13	Ville-sur-Jarnioux	69	Rhône	485300.00
14	Lyon 2e Arrondissement	69	Rhône	455217.26
15	Lyon 6e Arrondissement	69	Rhône	426968.25

```sql
WITH commune_moyenne AS (
    SELECT
        commune.nom_commune AS "Commune",
        departement.code_departement AS "Code Département",
        departement.nom_departement AS "Nom Département",
        AVG(vente.valeur) AS moyenne_valeur_fonciere,
        ROW_NUMBER() OVER (PARTITION BY departement.code_departement ORDER BY AVG(vente.valeur) DESC) AS rang
    FROM vente
    JOIN bien ON vente.id_bien = bien.id_bien
    JOIN commune ON bien.id_codedep_codecommune = commune.id_codedep_codecommune
    JOIN departement ON commune.code_departement = departement.code_departement
    WHERE departement.code_departement IN ('06', '13', '33', '59', '69')
    GROUP BY commune.nom_commune, departement.code_departement, departement.nom_departement
)
SELECT "Commune", "Code Département", "Nom Département",
       ROUND(moyenne_valeur_fonciere, 2) AS "Moyenne de la valeur foncière"
FROM commune_moyenne
WHERE rang <= 3
ORDER BY "Code Département", moyenne_valeur_fonciere DESC;
```

Requête 12

Les 20 communes avec le plus de transactions pour 1.000 habitants (pour les communes qui dépassent les 10.000 habitants)

	Commune character varying (100)	Population integer	Nombre de transactions bigint	Transactions pour 1000 habitants numeric
1	Paris 2e Arrondissement	21735	127	5.84
2	Paris 1er Arrondissement	16055	79	4.92
3	Paris 3e Arrondissement	34306	161	4.69
4	Arcachon	11898	55	4.62
5	La Baule-Escoublac	16797	77	4.58
6	Paris 4e Arrondissement	29390	120	4.08
7	Roquebrune-Cap-Martin	13041	52	3.99
8	Paris 8e Arrondissement	36250	139	3.83
9	Sanary-sur-Mer	17160	60	3.50
10	Paris 9e Arrondissement	60563	208	3.43
11	La Londe-les-Maures	10776	37	3.43
12	Paris 6e Arrondissement	41171	139	3.38
13	Saint-Cyr-sur-Mer	11725	38	3.24
14	Chantilly	11178	35	3.13
15	Pornichet	11440	35	3.06
16	Saint-Mandé	22576	69	3.06
17	Paris 10e Arrondissement	86863	264	3.04
18	Menton	30981	91	2.94
19	Saint-Hilaire-de-Riez	11501	33	2.87
20	Vincennes	50230	141	2.81

```sql
SELECT
  commune.nom_commune AS "Commune",
  commune.population AS "Population",
  COUNT(vente.id_vente) AS "Nombre de transactions",
  ROUND(
    (
      COUNT(vente.id_vente) * 1000.0
    ) / commune.population,
    2
  ) AS "Transactions pour 1000 habitants"
FROM
  commune
  JOIN bien ON commune.id_codedep_codecommune = bien.id_codedep_codecommune
  JOIN vente ON vente.id_bien = bien.id_bien
WHERE
  commune.population > 10000
GROUP BY
  commune.nom_commune,
  commune.population
ORDER BY
  "Transactions pour 1000 habitants" DESC
LIMIT
  20;
```

Merci !