ANALYSE DES VENTES

Laurent MAGANTO
Juillet 2025

LIBRARIE
Lapage

Contexte

Depuis son lancement e-commerce en mars 2021, Lapage a transformé son modèle (librairie physique > acteur digital).

Cette analyse couvre **2 années d'activité en ligne**, du **01/03/2021 au 28/02/2023**, période marquée par :

- une **montée en charge rapide**, suivie d'un pic en 2022,
- puis une tendance baissière à surveiller.

⚠ L'étude porte exclusivement sur les clients **(BtoC)** après exclusion des 4 clients BtoB les plus actifs (≈7 % du CA).

LES DONNÉES

DATASETS	LIGNES	COLONNES	CLES (PK, FK)	RÔLE PRINCIPAL
PRODUCTS	3 286	3	**Id_prod (PK)**	informations sur l'ensemble des produits référencés par la librairie (id, prix, catégorie)
TRANSACTIONS	687 534*	4	**session_id (PK)** Id_prod (FK), Client_id (FK)	contient l'historique des transactions effectuées par les clients sur le site (session_id, date, client, id_prod)
CUSTOMERS	8 621	3	**Client_id (PK)**	informations démographiques sur les clients de la librairie (genre, année de naissance)

** Après suppression de 361040 lignes vides*

OUTILS UTILISÉS :

python™ jupyter pandas plotly matplotlib seaborn

Synthèse des KPIs globaux

Indicateurs	Valeurs
Chiffre d'affaires total (€)	12 027 663
Nombre total de transactions	687 534
Nombre total de références produits au catalogue	3 286
Références produits vendues	3 265
Produits jamais vendus	21
Clients actifs (ayant acheté)	8 600
Clients inactifs	21
Clients BtoB	4
Nombre de sessions uniques	345 505

Nos clients

Statistiques sur l'âge des clients :

- Âge moyen client : 45 ans
- Client le plus jeune : 19 ans
- Client le plus âgé : 94 ans

Genre des clients	nombre de clients	pourcentage
Femmes	4 490	52,08 %
Hommes	4 131	47,92 %

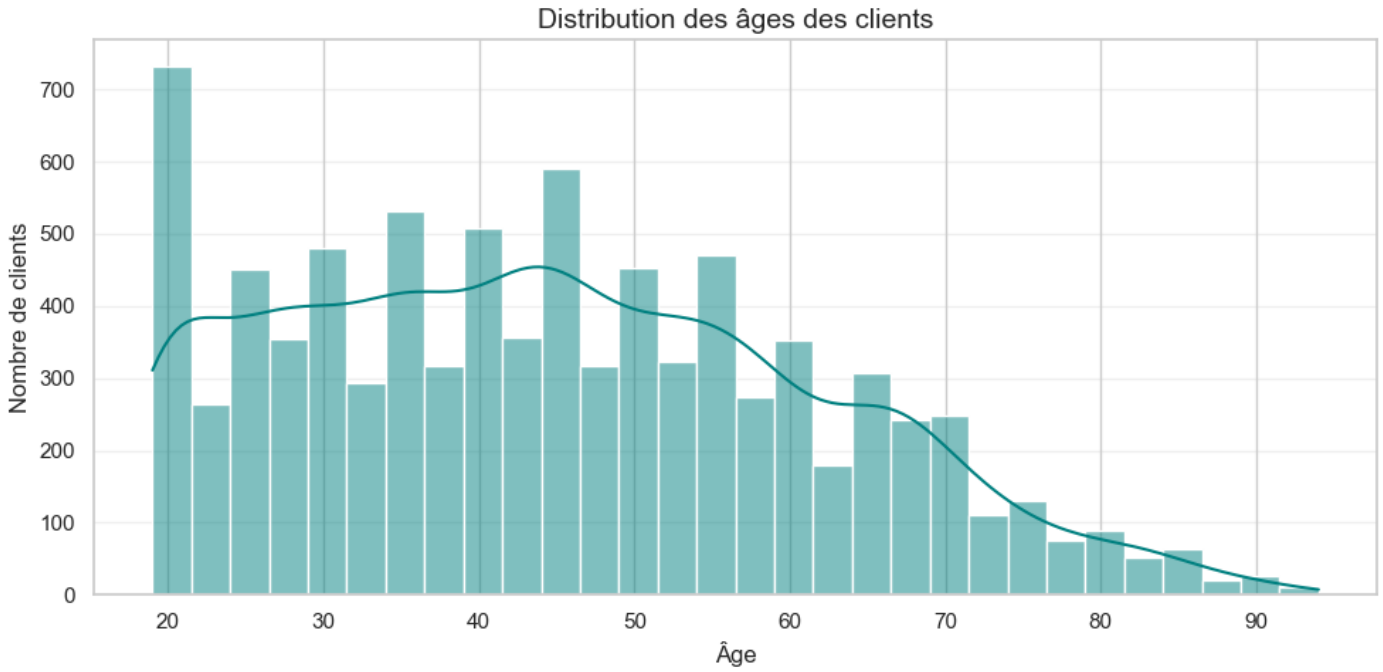

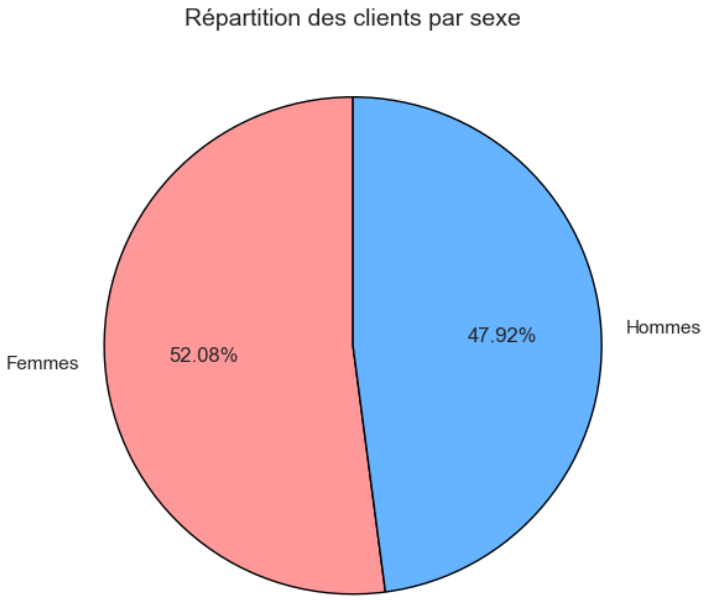

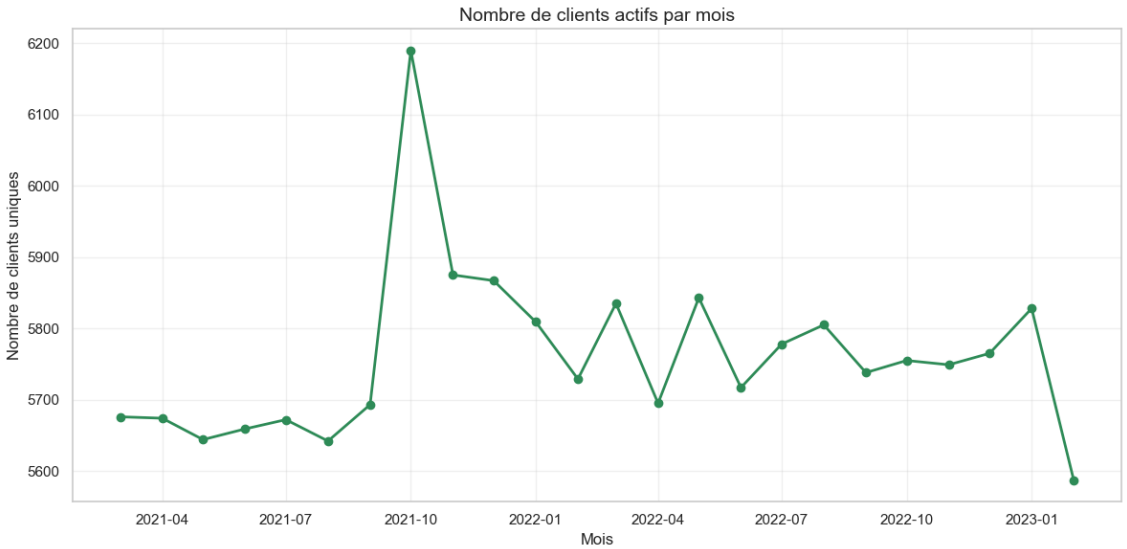

Nos clients : Répartition BtoB / BtoC

La base ***customers.csv*** ne contient **aucun champ identifiant explicitement les clients professionnels** (BtoB)

Approche alternative : analyse des **clients ayant effectué le plus grand nombre d'achats sur la période** (les clients dont le **volume de commandes est très élevé** pourraient **raisonnablement être considérés comme professionnels)**

client_id	Nombre de ventes
c_1609	**25 586**
c_6714	**9 199**
c_3454	**6 793**
c_4958	**5 222**
c_2140	405
c_3263	403
c_2595	398
c_2077	386
c_1637	384
c_7421	381

Les quatre premiers clients cumulent **46 800 transactions**, soit une part significative de l'activité.

Ces volumes sont **nettement supérieurs aux comportements d'achat attendus pour des particuliers**, ce qui permet de considérer qu'il s'agit **très probablement de clients professionnels (BtoB)**.

Estimation du chiffre d'affaires BtoB :

En considérant les 4 clients ayant réalisé plus de 5 000 transactions comme des **acheteurs professionnels**, nous estimons que :

- ils génèrent à eux seuls **884 296.09 €** de chiffre d'affaires,
- soit **7.35 %** du chiffre d'affaires total de la période.

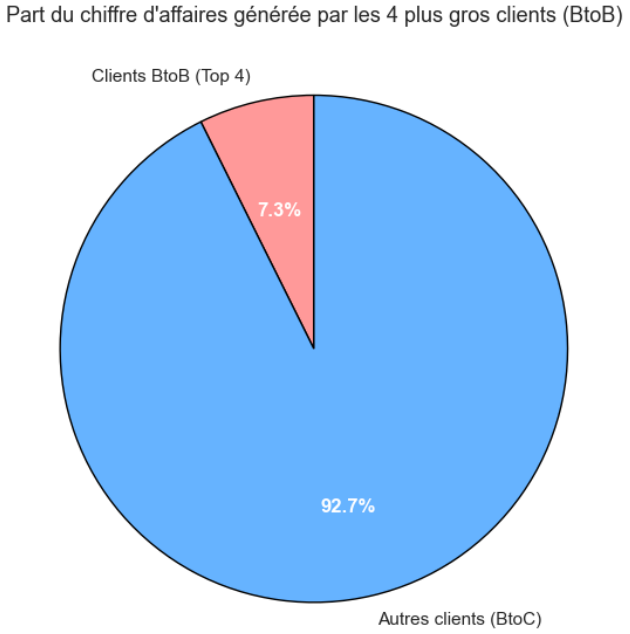

Ces clients BtoB ont été exclus des analyses comportementales

Nos produits

Statistiques descriptives de nos produits:

Nombre total de références produits au catalogue	3 286
Références produits vendues	3 265
Produits jamais vendus	21
Catégories de produits	3

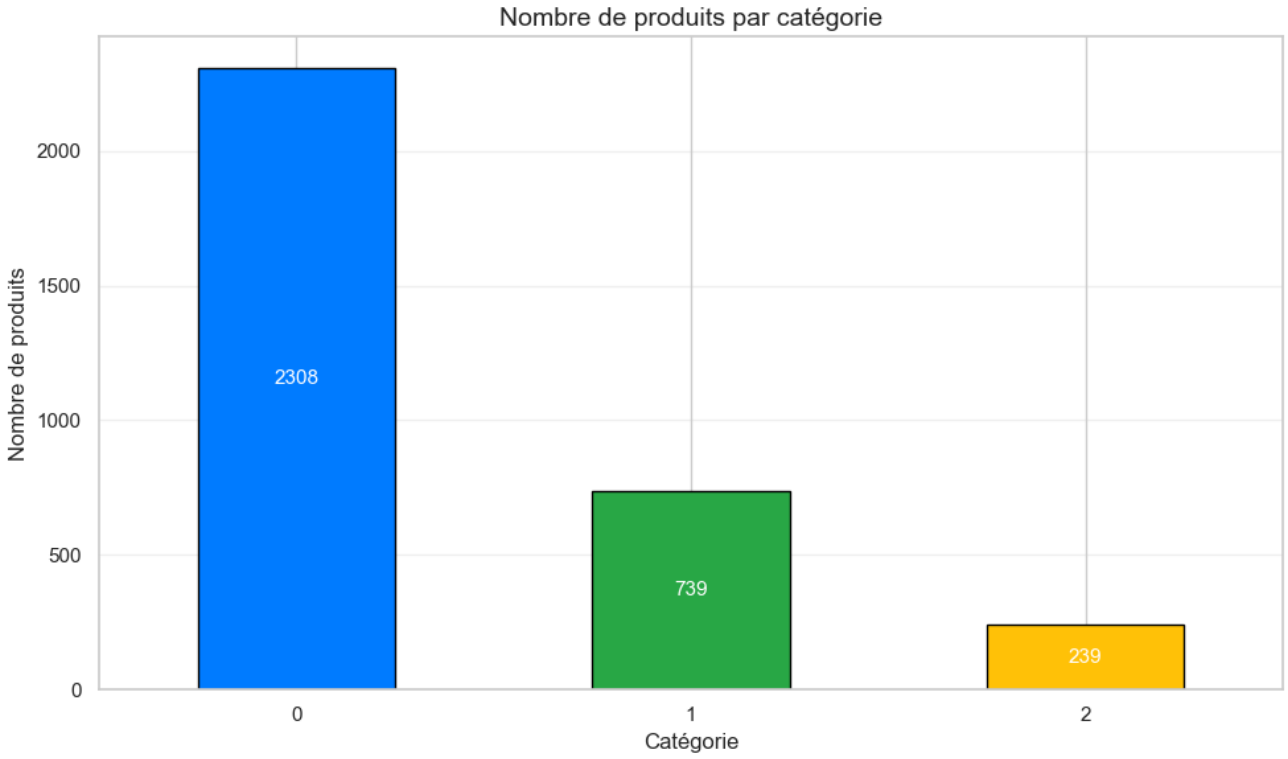

Statistiques descriptives sur les prix :

Prix moyen	21,86 €
produit le moins cher	0,62 €
Produit le plus cher	300 €

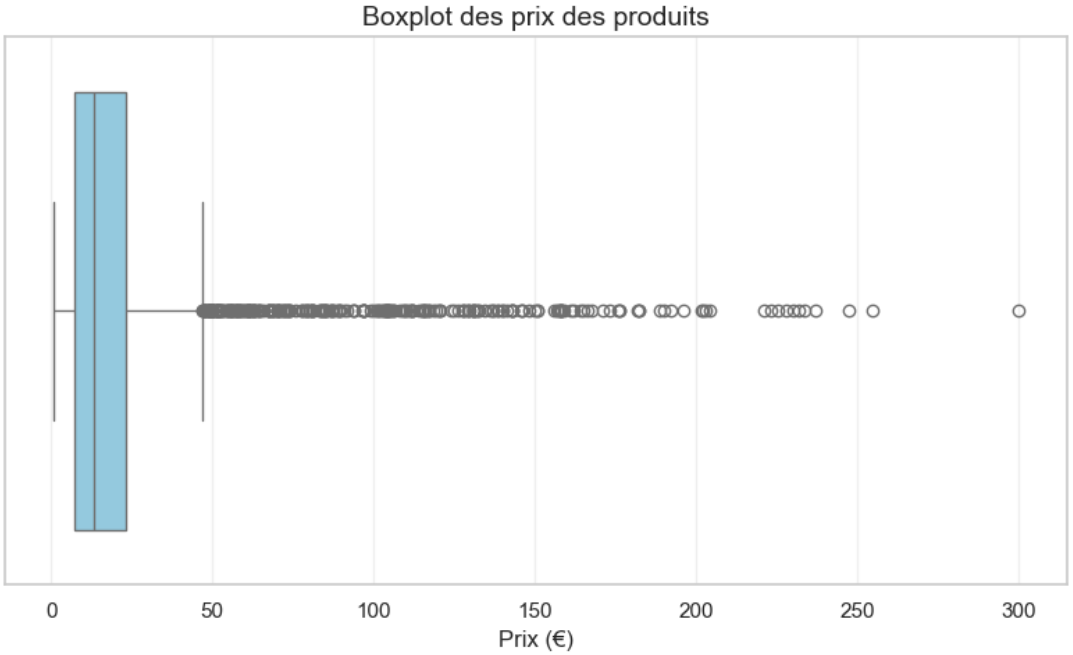

Nombre de produits considérés comme outliers : 302

Les transactions

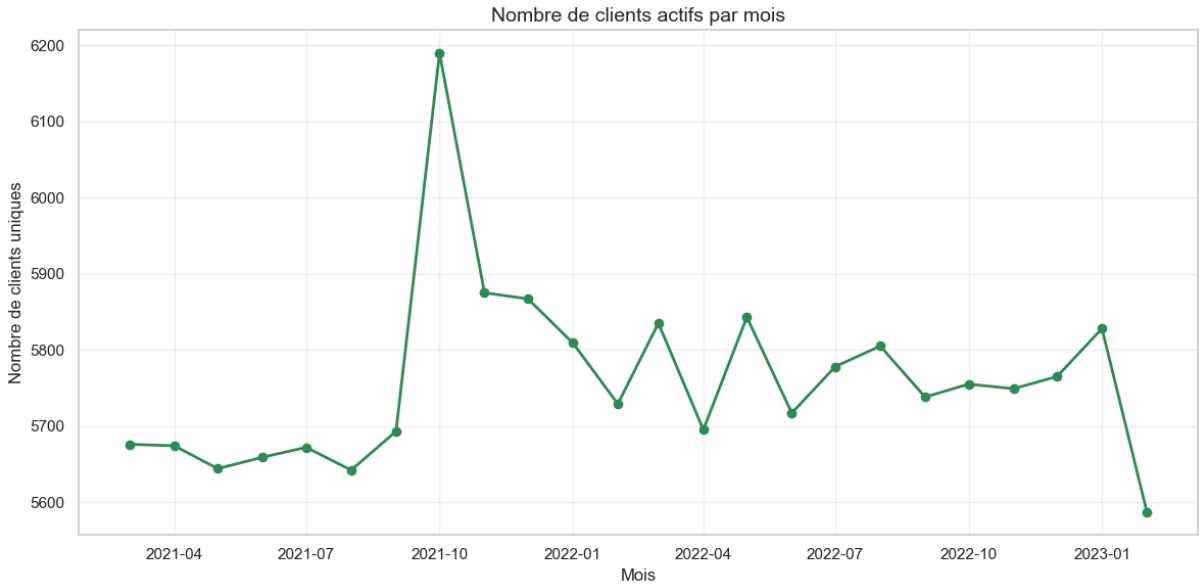

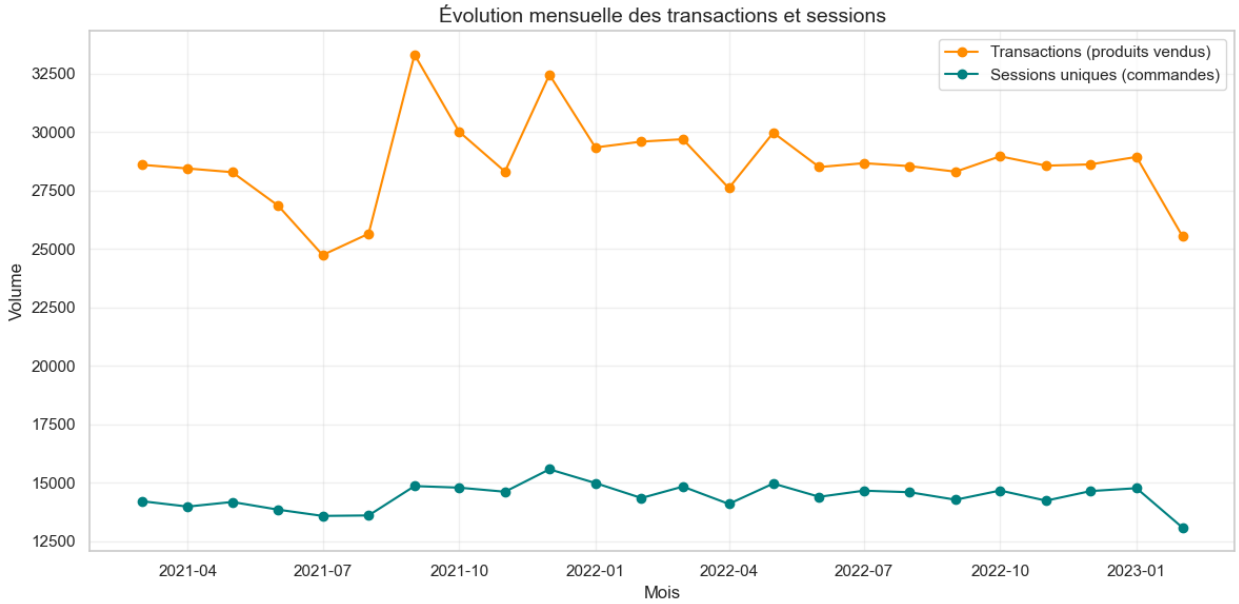

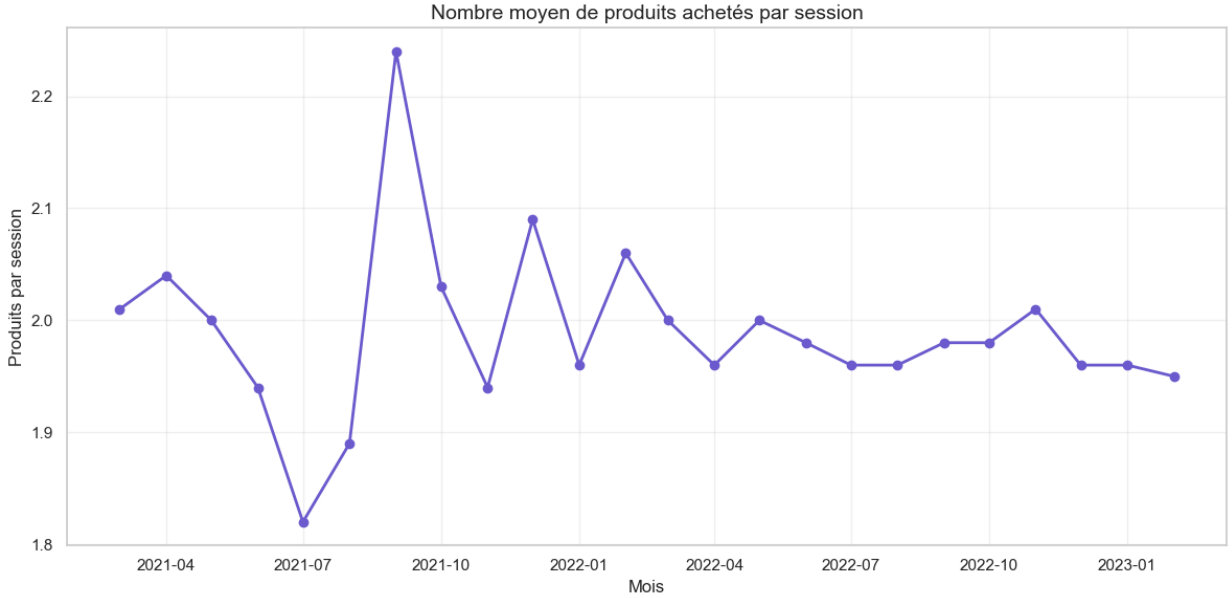

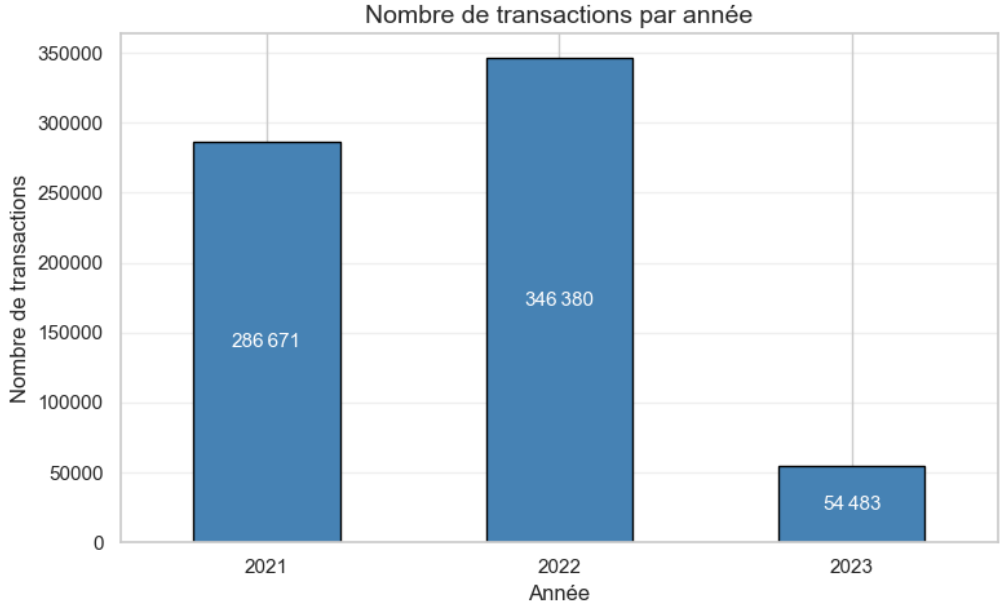

Nombre moyen de produits par session : **1,9 à 2,1 produits par commande** sur l'ensemble de la période

Évolution du chiffre d’affaires

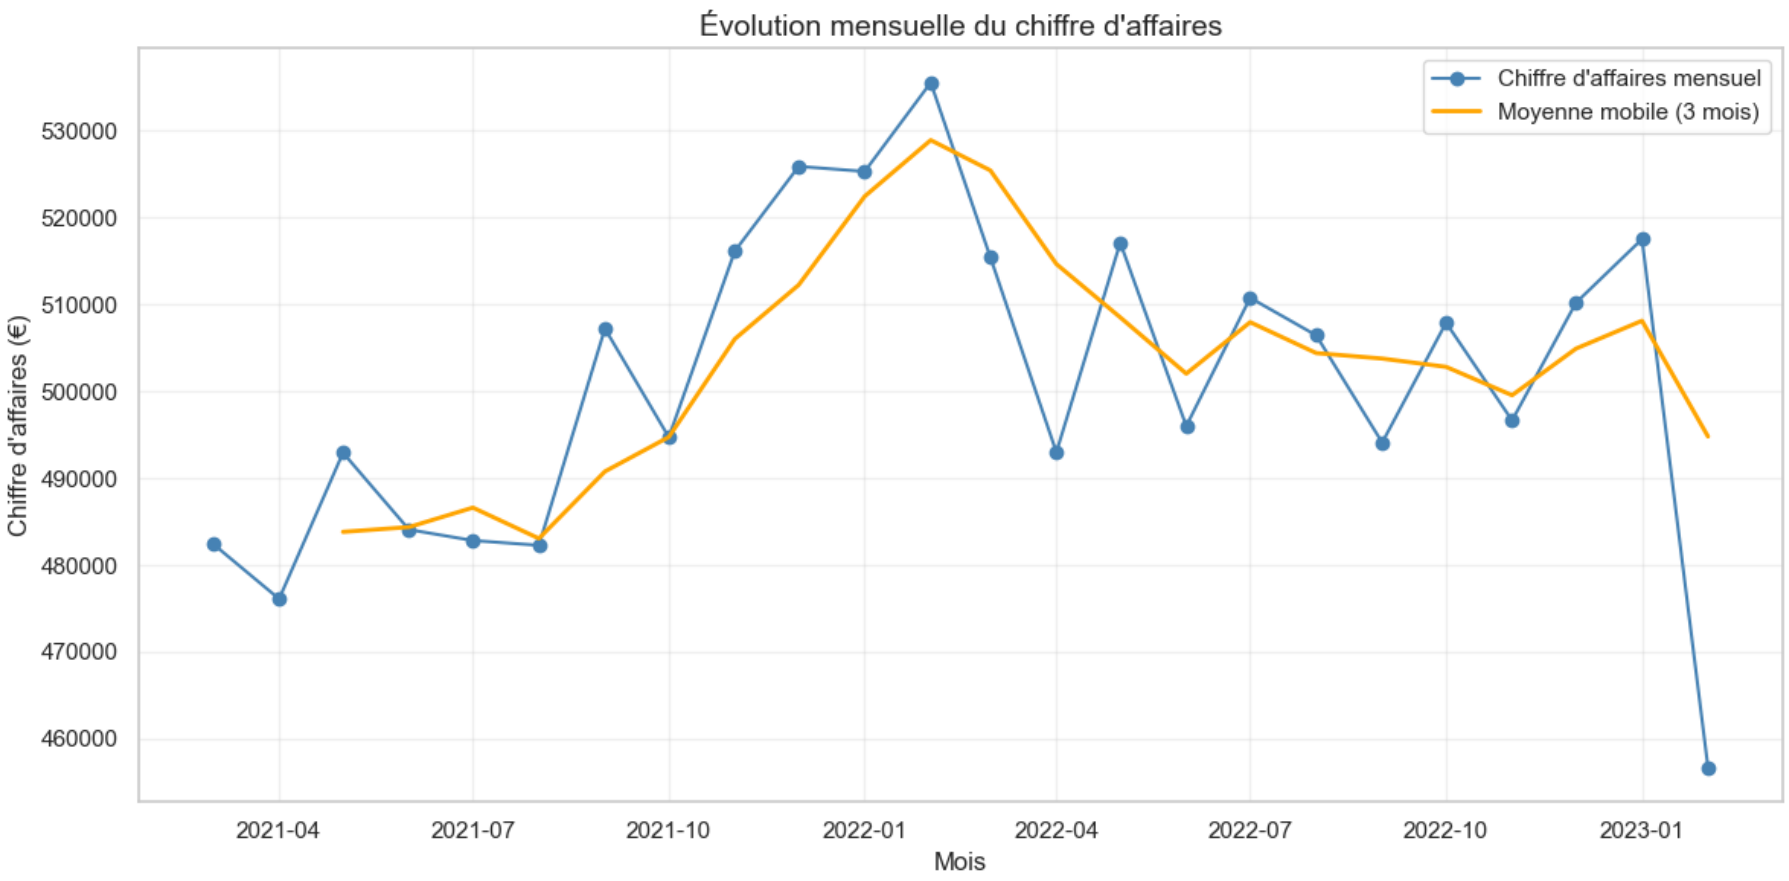

La courbe permet de visualiser clairement l’évolution du chiffre d’affaires mois par mois, qui permet de constater :

- une montée en charge progressive à partir du lancement en mars 2021,
- un **pic d’activité** visible **début 2022**,
- une **tendance à la baisse** au cours de l’année **2022**,
- une baisse très nette en début 2023, cohérente avec la couverture partielle de la période (janvier-février uniquement).

La **moyenne mobile sur 3 mois** permet de lisser les variations ponctuelles et de mieux faire ressortir la tendance générale.

Catégories qui performent

Catégorie de produits	Produits vendus (volume)	Chiffre d'affaires (€)	Prix moyen (€)
0	**415 459**	4 419 730.97 €	10.64 €
1	235 592	**4 827 657.11 €**	20.49 €
2	36 483	2 780 275.02 €	**76.21 €**

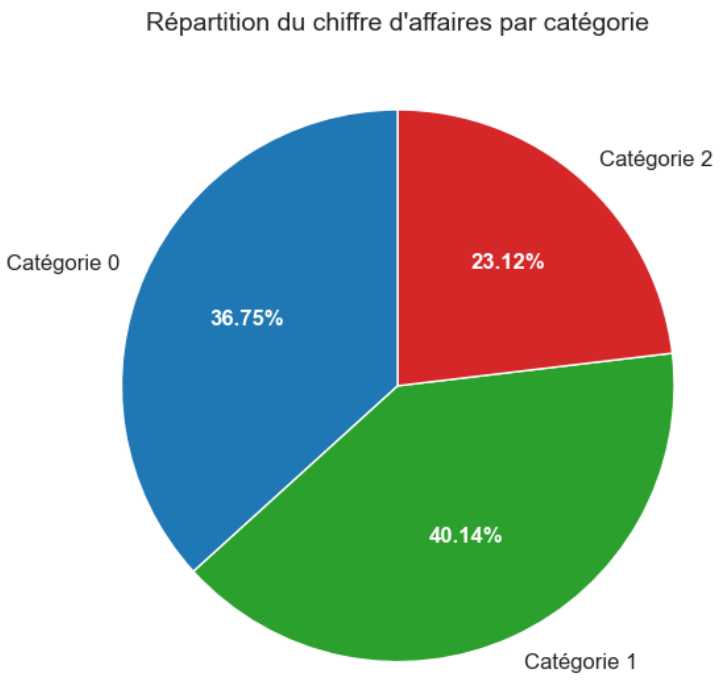

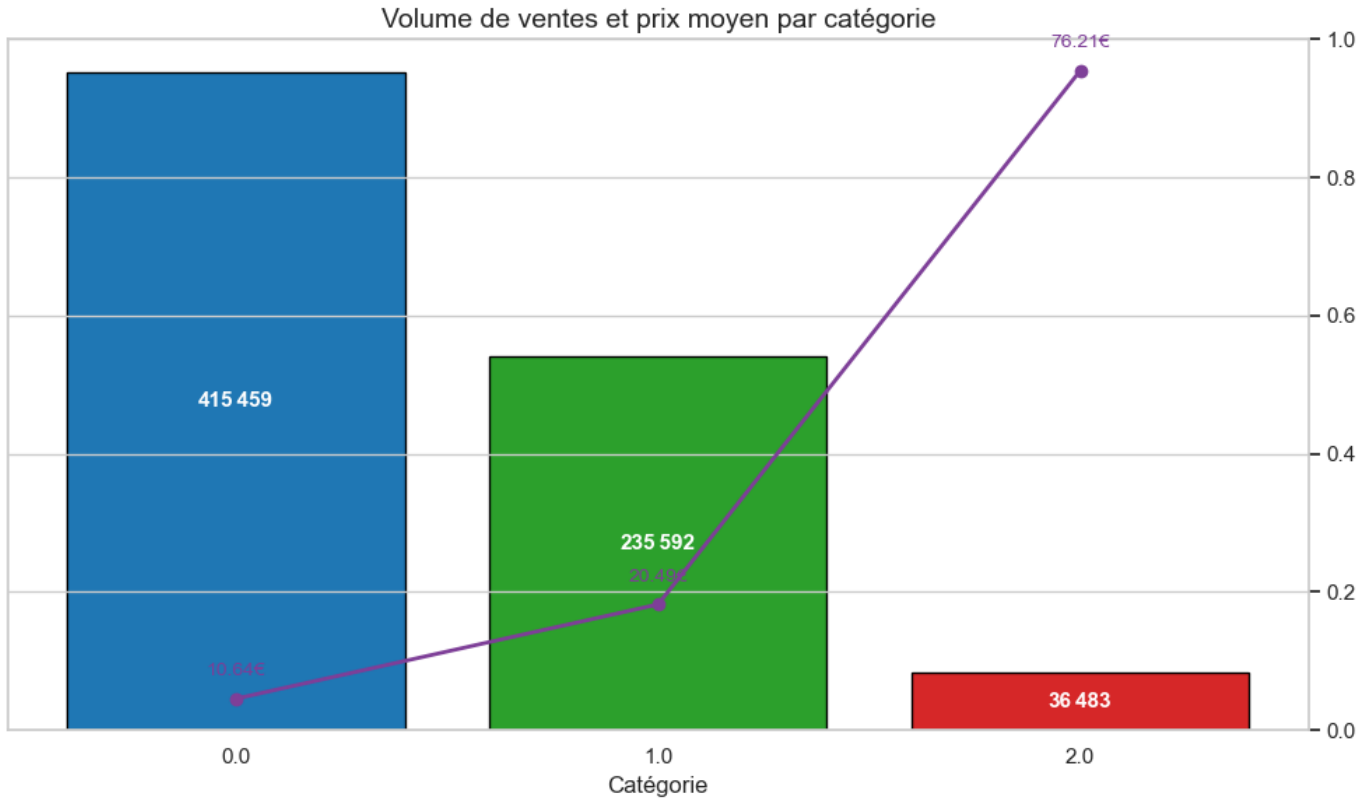

Focus Top / Flop des références

TOP des produits les plus vendus :

classement	id_prod	Nombre de ventes
1	1_369	2 340
2	1_417	2 269
3	1_414	2 246
4	1_498	2 202
5	1_425	2 163
6	1_403	2 040
7	1_413	2 036
8	1_412	2 014
9	1_406	2 003
10	1_407	2 001

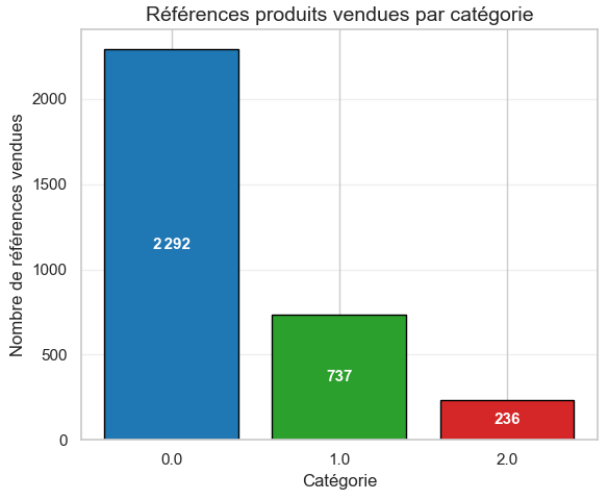

FLOP - Nombre de produits jamais achetés: 21

id_prod	price	categ
0_1016	35.06	0.0
0_1780	1.67	0.0
0_1062	20.08	0.0
0_1119	2.99	0.0
0_1014	1.15	0.0
1_0	31.82	1.0
0_1318	20.92	0.0
0_1800	22.05	0.0
0_1645	2.99	0.0
0_322	2.99	0.0
0_1620	0.80	0.0
0_1025	24.99	0.0
2_87	220.99	2.0
1_394	39.73	1.0
2_72	141.32	2.0
0_310	1.94	0.0
0_1624	24.50	0.0
2_86	132.36	2.0
0_299	22.99	0.0
0_510	23.66	0.0
0_2308	20.28	0.0

En complément, nous avons également repéré **44 produits vendus une ou deux fois seulement**, qui peuvent être considérés comme des **flops commerciaux**.

Courbe de Lorenz

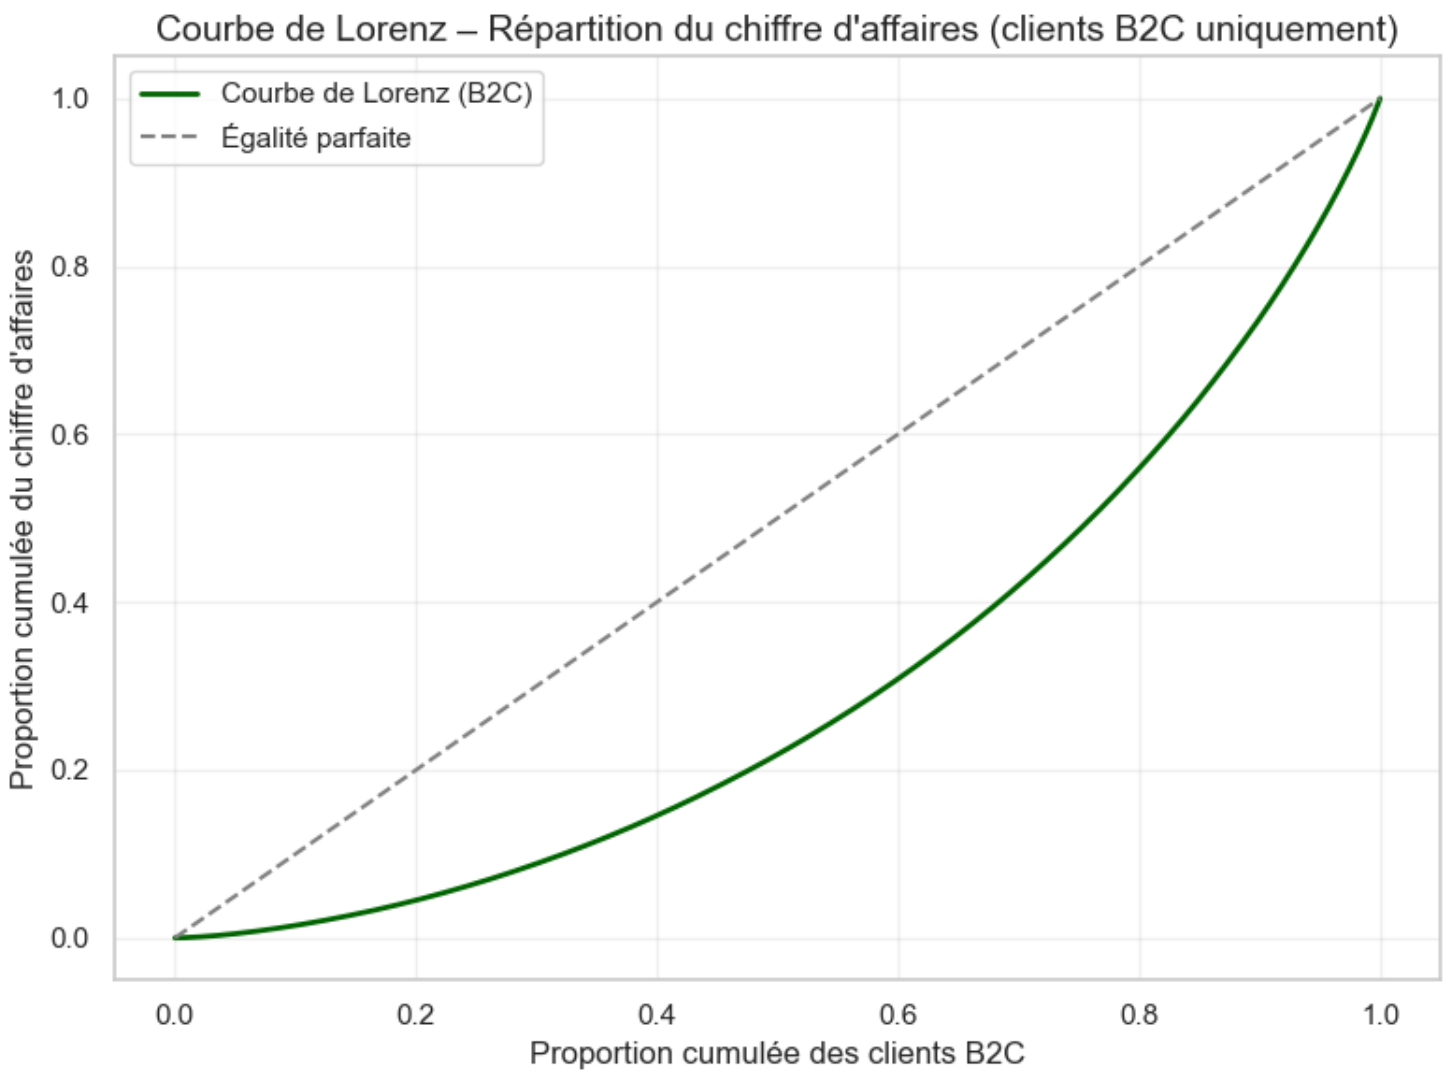

La Courbe de Lorenz :

- La courbe est nettement éloignée de la diagonale, ce qui montre une forte concentration du chiffre d'affaires :
- Une **petite proportion de clients** génère une **part très importante du CA**.
- **Implication :** concentrer les efforts CRM sur les **clients à fort potentiel**, tout en réfléchissant à l'**activation des clients peu contributeurs**.

Indice de Gini = 0,3983

- **Inégalité modérée** : une partie relativement restreinte des clients contribue à une grande part du chiffre d'affaires total.
- Cette observation confirme la courbe de Lorenz : le chiffre d'affaires n'est pas réparti uniformément dans la base clients.

Corrélation entre le genre et les catégories de livres achetés

Genre	Catégorie 0	Catégorie 1	Catégorie 2
Femmes	200 793	115 721	16 980
Hommes	186 488	104 884	15 868

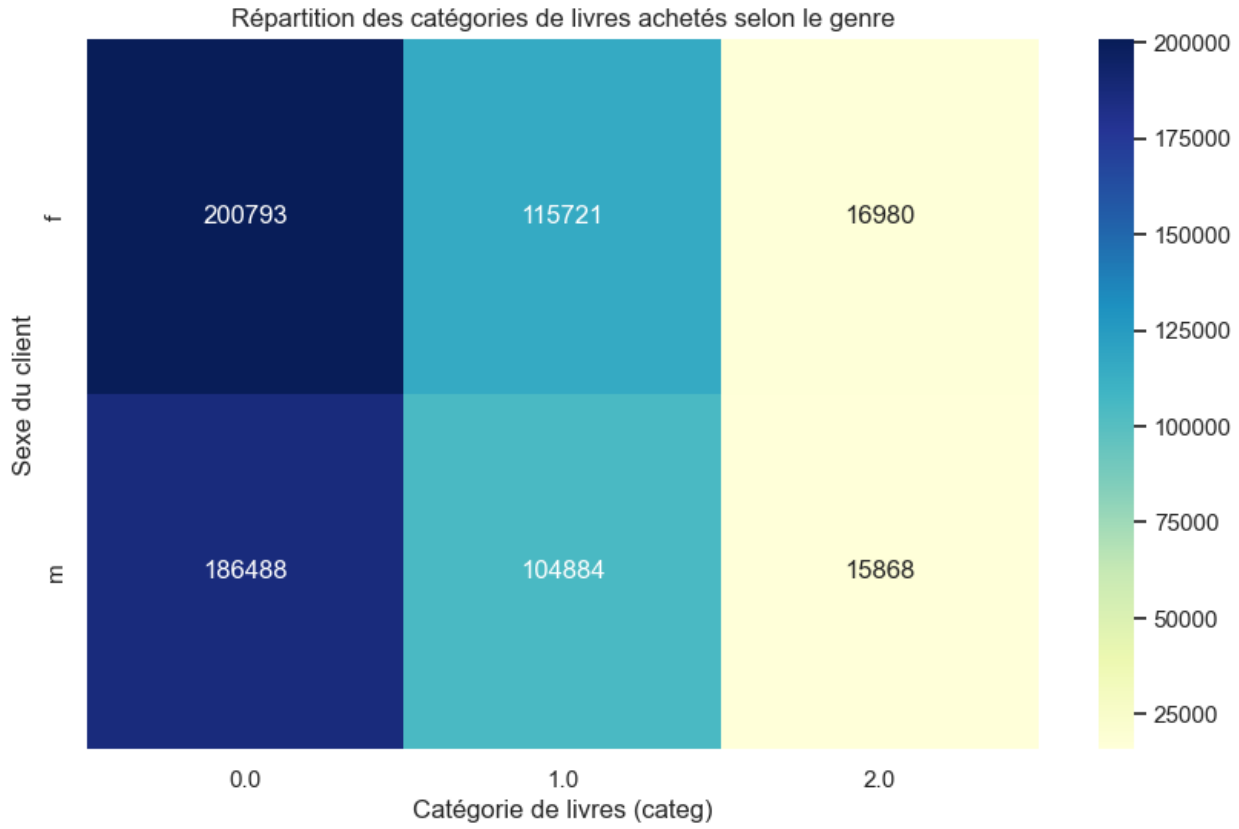

2 variables **qualitatives**

Le **test du Chi-2** permet d'évaluer s'il existe un lien entre le genre du client et la catégorie de livres achetés.

- Statistique de test : 22.67
- Degrés de liberté : 2
- Valeur p : 0.00001196

Il existe une association statistiquement significative entre le genre et les catégories de livres achetées.

Le genre influence légèrement les choix de catégories de livres, mais l'écart observé reste modéré en pratique.

Corrélation entre l'âge des clients et le montant total de leurs achats

2 variables **quantitatives**

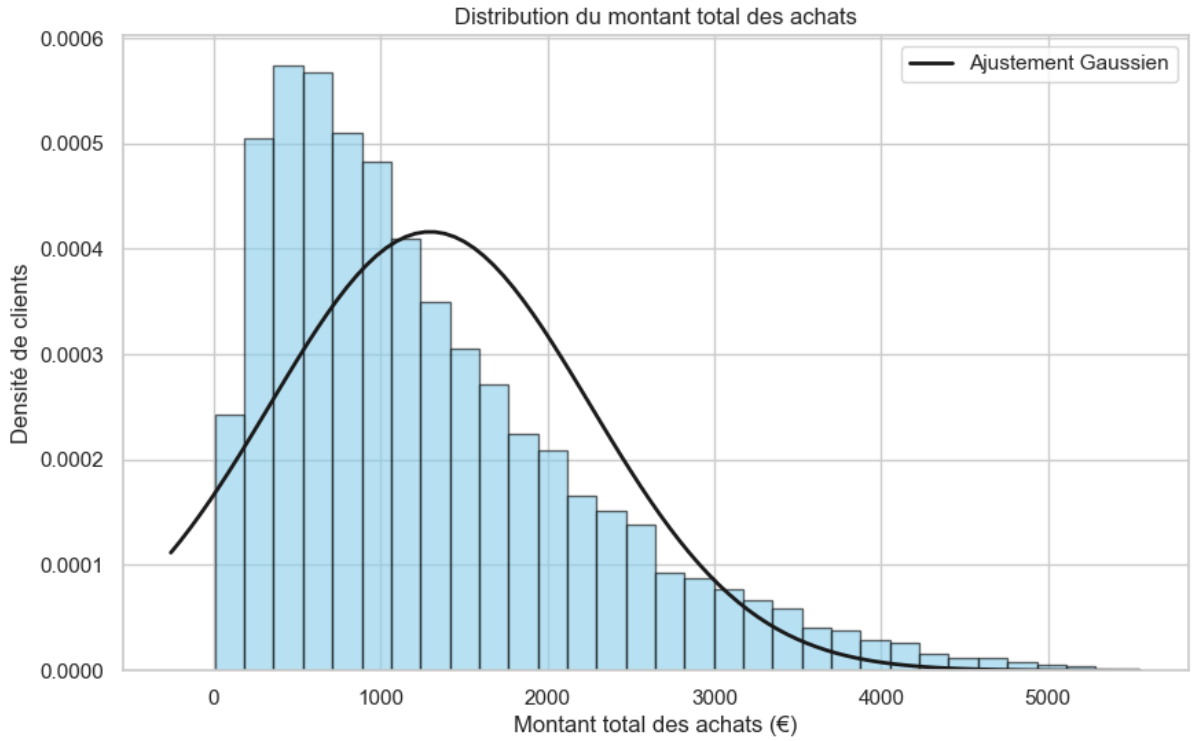

Statistiques descriptives :

- Moyenne du montant total des achats : **1 296,34 €**
- Écart-type : **958,40 €**

Cette distribution n'est pas gaussienne (non symétrique).

Application du **test de Spearman :**

- Coefficient de Spearman : **-0.1845**
- Valeur p : 0.000000000000
- Corrélation significative entre l'âge et le montant total des achats.

Faible corrélation négative : **les clients plus âgés ont tendance à dépenser un peu moins que les plus jeunes**

Confirmé visuellement :

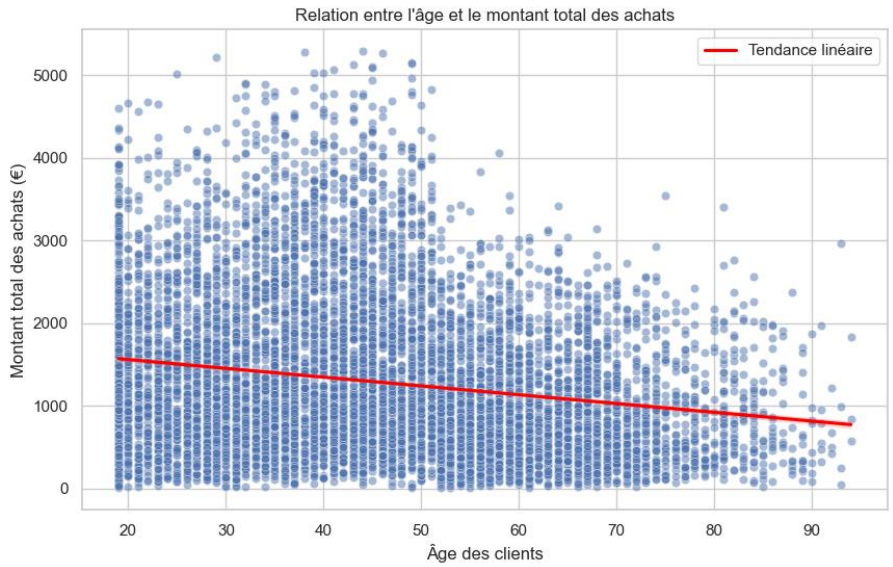

Corrélation entre l'âge et la fréquence d'achat

2 variables **quantitatives**

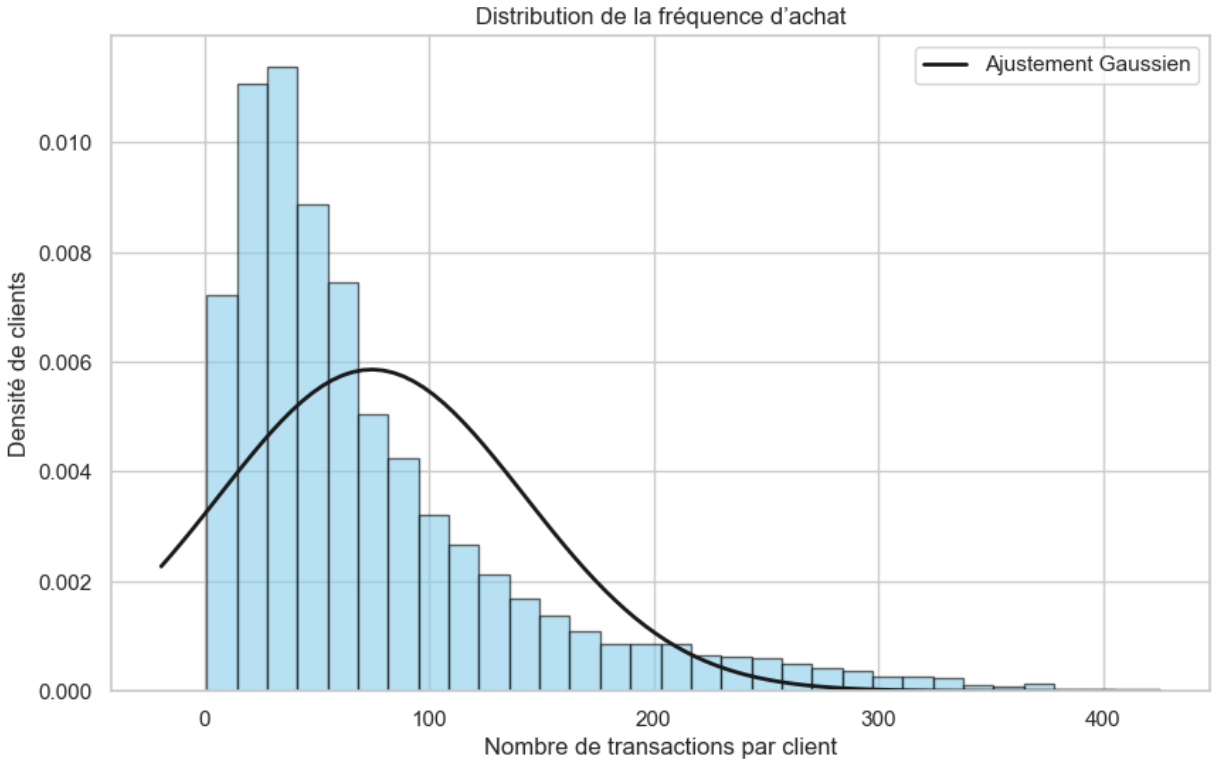

Statistiques descriptives :

- Moyenne : **74,54 transactions**
- Écart-type : **68,07**

Cette distribution **ne semble pas suivre une courbe gaussienne** (courbe noire), car elle est étalée vers la droite.

Test de normalité (test de **Shapiro-Wilk**) :

- Statistique de Shapiro-Wilk : **0.8167**
- Valeur p : **0.000000**
- la variable *frequence_achat* **ne suit pas une loi normale**

Application du **test de Spearman :**

- Coefficient de Spearman : **0.1277**
- Valeur p : **0.000000**
- Corrélation significative entre l'âge et la fréquence d'achat.

Faible corrélation positive : **les clients plus âgés ont, en moyenne, une fréquence d'achat un peu plus élevée**

Confirmé visuellement :

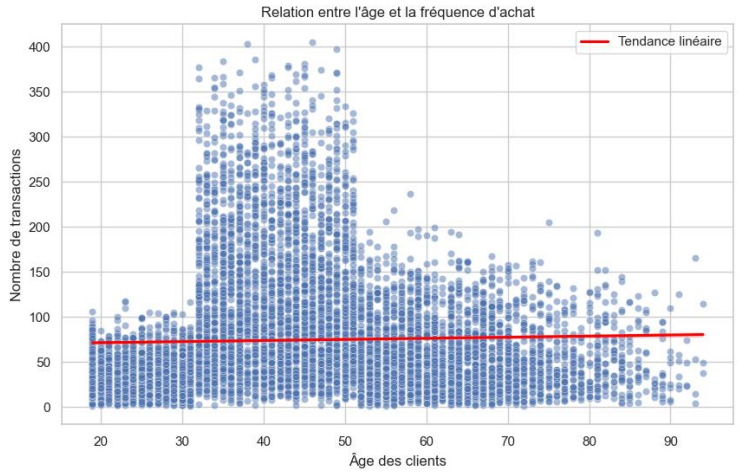

Corrélation entre l'âge et le panier moyen

2 variables **quantitatives**

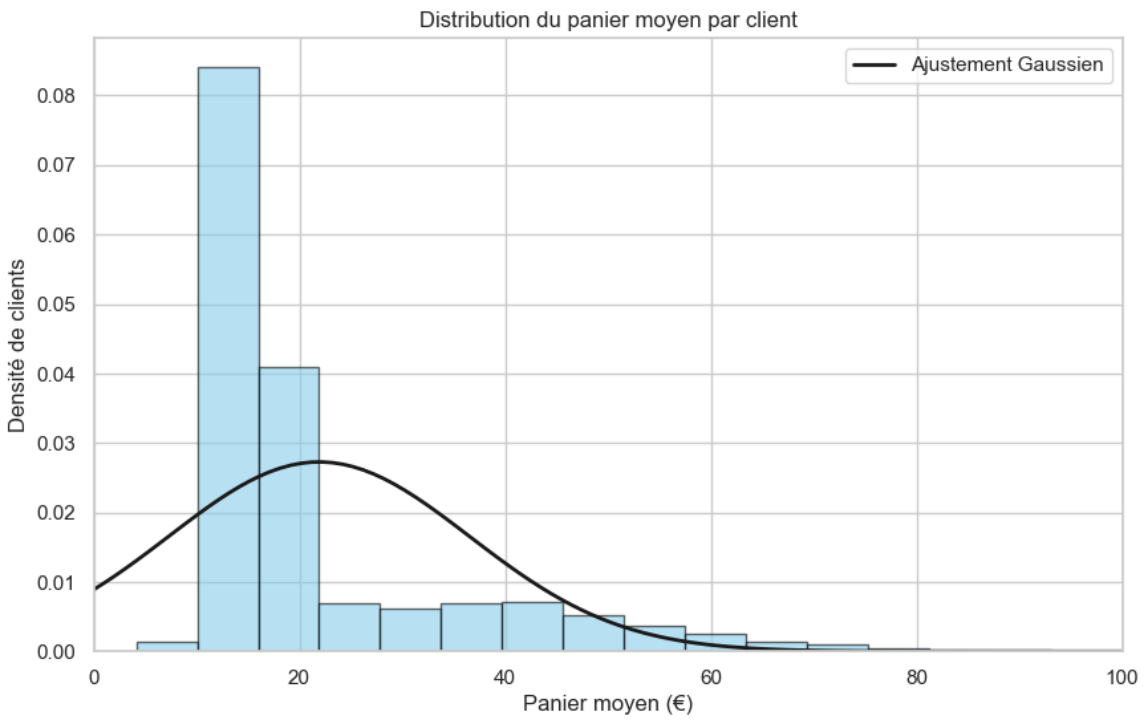

Statistiques descriptives :

- Moyenne du panier moyen : **21,93 €**
- Écart-type : **14,63 €**

Cette distribution **ne semble pas suivre une courbe gaussienne** (courbe noire), car elle est étalée vers la droite.

Test de normalité (test de **Shapiro-Wilk**) :

- Statistique de Shapiro-Wilk : **0.6828**
- Valeur p : **0.000000**
- la variable *panier_moyen* **ne suit pas une loi normale**

Application du **test de Spearman :**

- Coefficient de Spearman : **- 0.3259**
- Valeur p : **0.000000**
- Corrélation significative entre l'âge et le panier moyen

Corrélation négative modérée : **plus les clients sont âgés, plus leur panier moyen a tendance à être faible**

Confirmé visuellement :

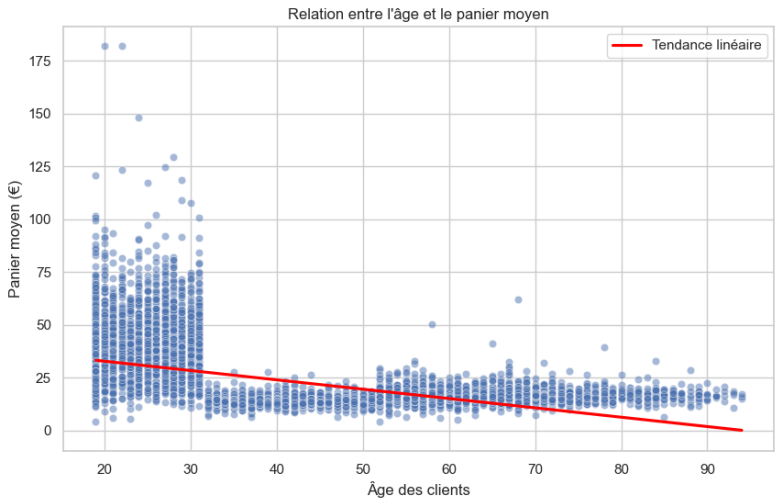

Corrélation entre l'âge et la catégorie de livres achetés

1 variable **quantitative (âge)** et 1 **qualitative (catégorie)**

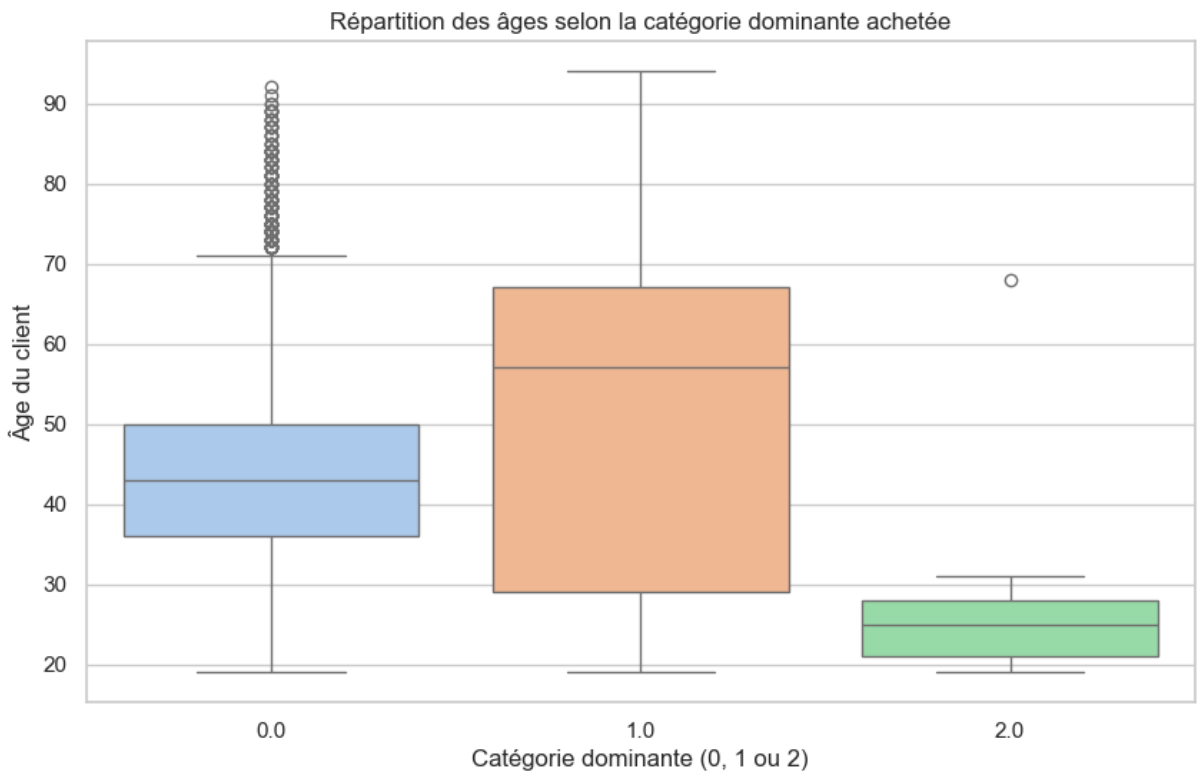

On observe visuellement des différences marquées entre les groupes :

- Les clients achetant majoritairement des livres de catégorie 1 semblent en moyenne plus âgés.
- Ceux préférant la catégorie 2 sont globalement plus jeunes.
- Le groupe de la catégorie 0 est plus concentré autour de 40–50 ans.

Les médianes sont différentes, et la variabilité (écart interquartile) varie aussi d'un groupe à l'autre. Ces éléments visuels laissent penser qu'il pourrait exister une différence significative des âges moyens selon la catégorie dominante.

Test de normalité (test de **Shapiro-Wilk**) dans chaque groupe de *categorie_dominante*, pour tester la normalité de la variable *age* :

- les **valeurs p sont toutes très largement inférieures à 0,05**, ce qui signifie que l'écart à la normalité est **statistiquement significatif**

Application du **test de Kruskal-Wallis :**

- Statistique de Kruskal-Wallis : **2134.8539**
- Valeur p : **0.000000**
- Il existe une différence significative d'âge entre au moins deux groupes.

L'âge des clients varie en fonction de la catégorie de livres qu'ils achètent le plus fréquemment.

Ce résultat confirme visuellement ce que nous avions observé dans le boxplot : les profils d'âge sont distincts selon la catégorie dominante.

Synthèse et recommandations

Synthèse des enseignements :

- **Une activité concentrée :**
  - **46 % du CA généré par 10 % des clients** (indice de Gini = 0,40)
  - Une poignée de **best-sellers drive la performance**

- **Des comportements différenciés selon les profils :**
  - **Les femmes privilégient certaines catégories**, tendance significative
  - **Les plus jeunes dépensent plus par panier**, mais achètent moins souvent
  - **Les plus âgés achètent plus fréquemment**, mais avec un panier plus faible

Recommandations stratégiques :

- **Optimiser l'offre produit** :
  - Mettre en avant les best-sellers (références locomotives)
  - Rationaliser les références peu performantes

- Des **Cibler finement les profils***
  - Adapter les offres et recommandations selon l'âge et le genre
  - Explorer des campagnes CRM personnalisées (panier moyen, fréquence)

- **Fidéliser et réactiver :**
  - Renforcer la fidélisation des clients à fort potentiel
  - Mettre en place des actions ciblées pour les inactifs