Détection automatique de faux billets

Rapport de mission - février 2026

ONCFM

La mission :
sécuriser et automatiser la détection de faux billets

Lent & Subjectif

La détection manuelle actuelle est un goulot d'étranglement face à la menace de la contrefaçon.

Solution

Identifier les motifs géométriques

Algorithme prédictif de haute précision

Outil opérationnel pour les agents

Objectif : créer une barrière technologique infranchissable

ONCFM

Analyse du jeu de Données

Dataset :

- **Source :** fichier CSV
  1.500 billets numérisés
- **Répartition :** **1.000 vrais** (authentiques) /
  500 faux (contrefaçons)
- **Variables :** 6 dimensions géométriques (mm)
- **Etat :** données globalement propres

Billets :

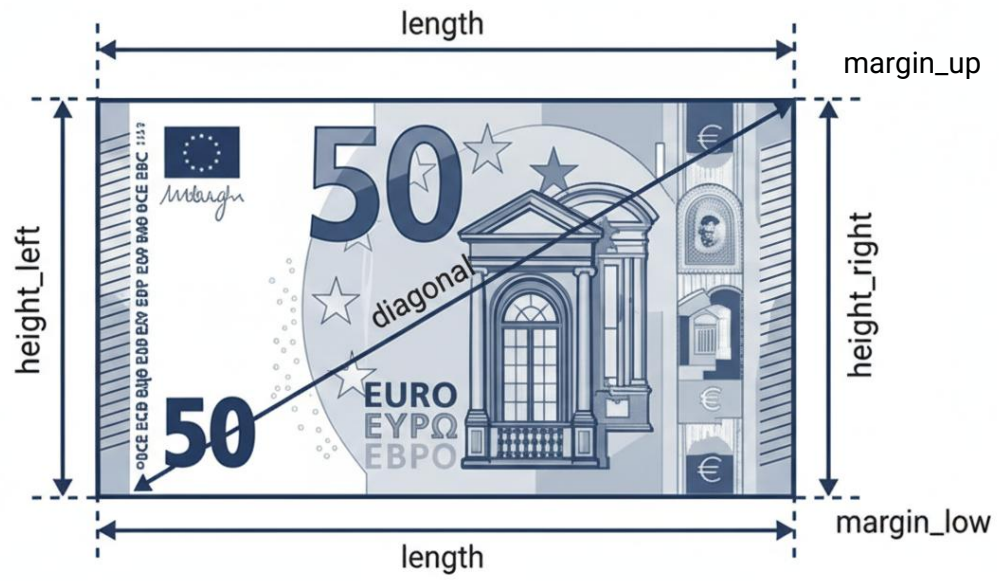

ONCFM

Exploration des Données

- **Séparation visuelle partielle des classes :**

  Les variables *length* et *margin_low* montrent une différenciation visible entre vrais et faux billets.

- **Distribution distincte :**

  Les densités indiquent des décalages moyens entre les deux classes.

- **Chevauchement existant :**

  La séparation n'est pas parfaite → **nécessité d'un modèle de classification**.

Visualisation pairplot

Exploration visuelle des relations entre les différentes variables numériques du dataset

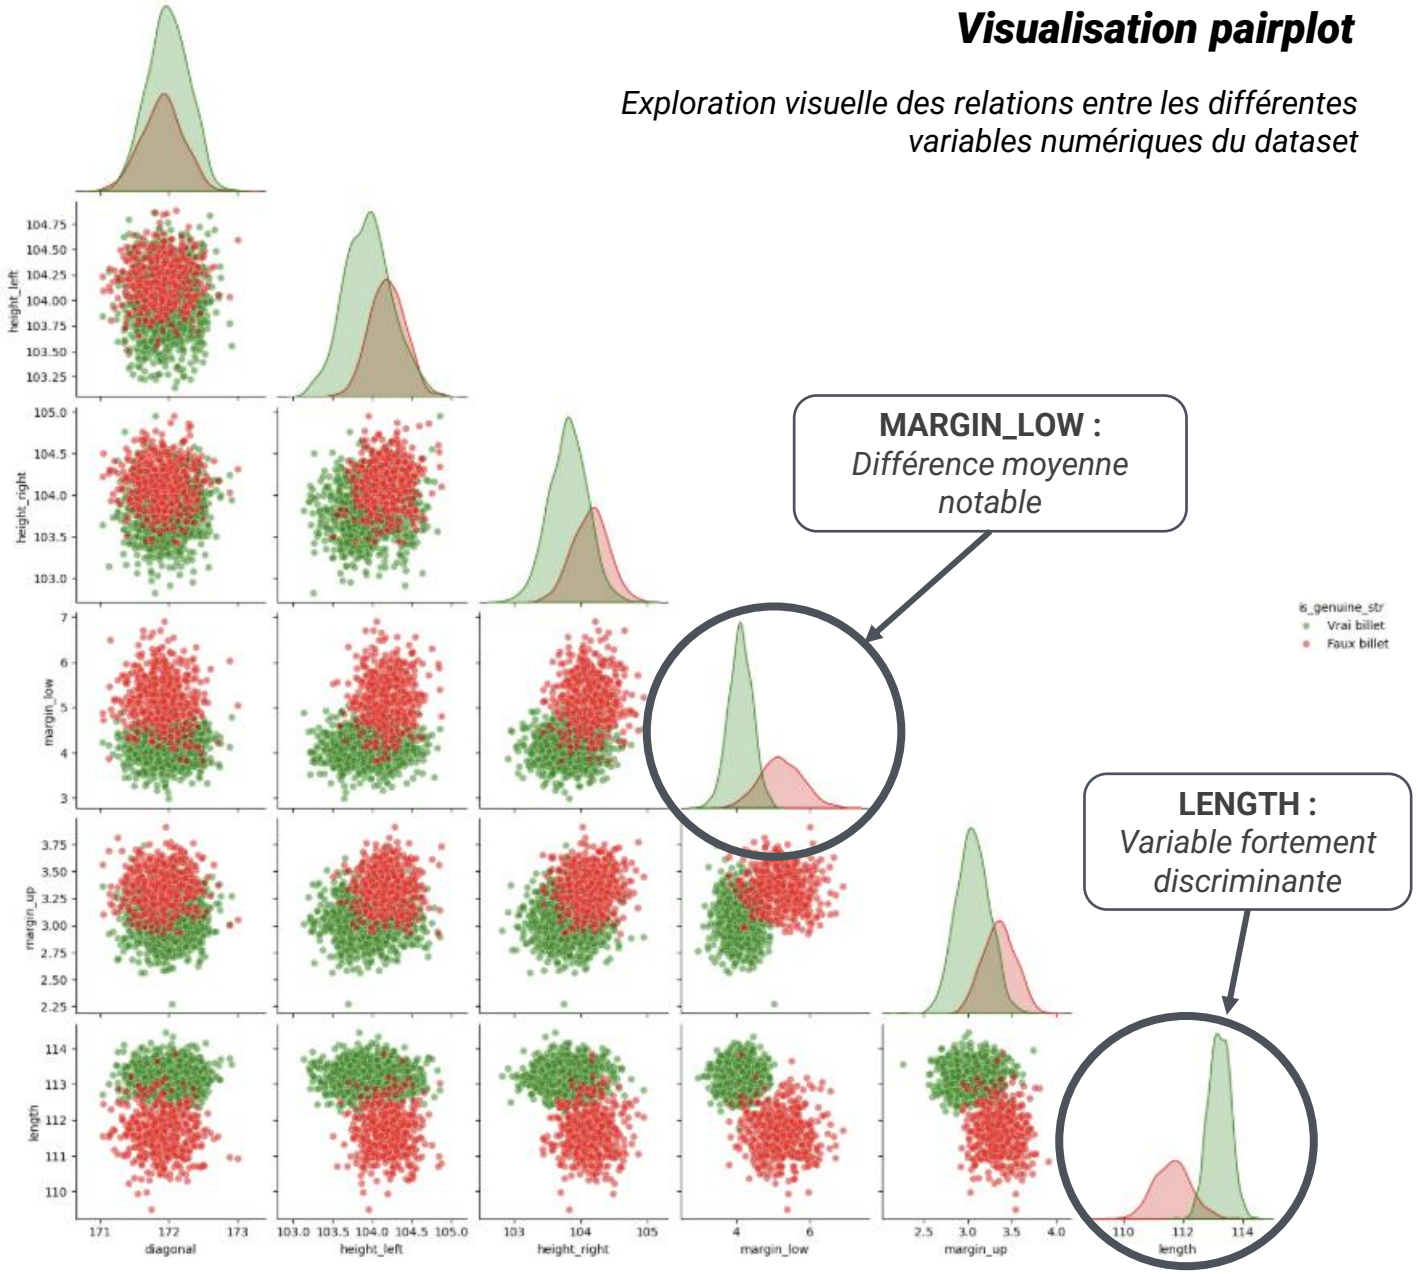

ONCFM

Nettoyage des données : l'impasse de l'imputation

Le problème

1.500 billets

Données incomplètes

37 valeurs manquantes sur la variable '***margin_low***' (2,47 % du *dataset*)

- ✓ Vrais billets : 29
- ✓ Faux billets : 8

L'enquête statistique

Tentative de régression linéaire :

► **ECHEC**

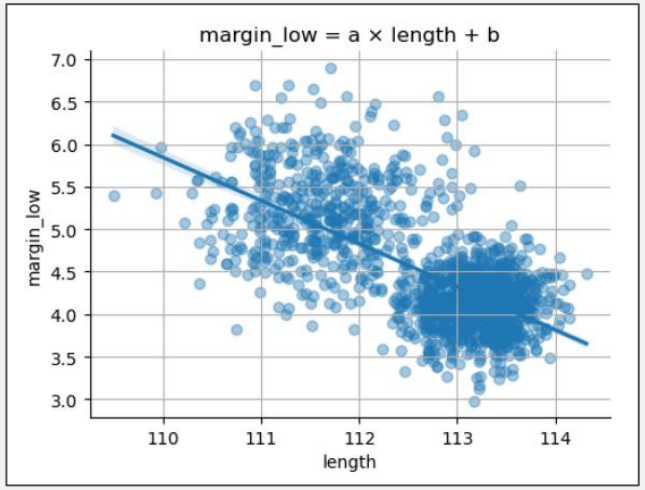

Constat :

- Corrélation modérée entre *length* et *margin_low*
- Dispersion importante autour de la droite de régression
- Résidus non homogènes

Test statistique :

- **Test de Breusch-Pagan**
  → hétéroscédasticité significative détectée
- Violation de l'hypothèse d'homoscédasticité

CONCLUSION : Le modèle linéaire ne permet pas une imputation statistiquement robuste.

ONCFM

Décision méthodologique : priorité à la fiabilité

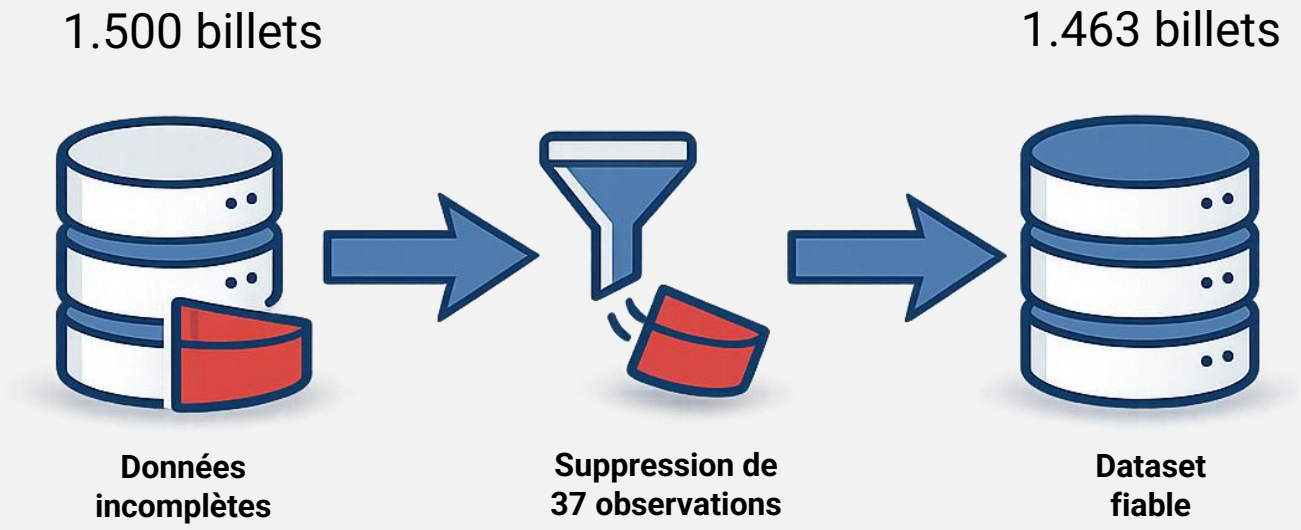

Justification : Mieux vaut un jeu de données légèrement réduit qu'un modèle entraîné sur des données artificiellement imprécises.

ONCFM

Préparation des Données pour la modélisation

Standardisation des variables (centrage-réduction)

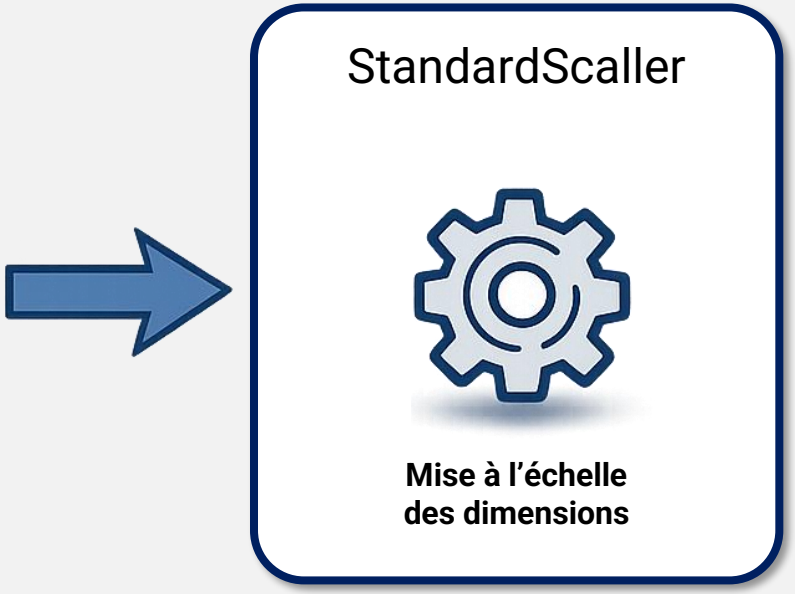

- Les variables géométriques présentent des ordres de grandeur différents.
- Un **StandardScaler** est appliqué afin de centrer les variables (moyenne = 0) et les réduire (écart-type = 1).
- Cela garantit une contribution équilibrée de chaque variable dans les modèles sensibles aux distances.

Séparation du jeu de données : Train / Test (80 % / 20 %)

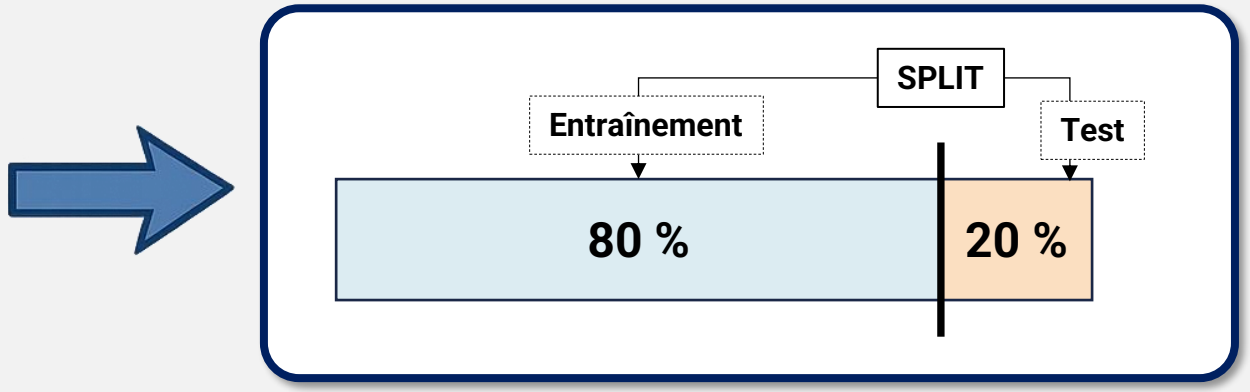

Le dataset est scindé en deux ensembles distincts :

- **Train (80 %)** : apprentissage des paramètres du modèle
- **Test (20 %)** : évaluation sur des données non utilisées pendant l'entraînement

La séparation est effectuée avec ***stratify=y*** afin de conserver la proportion de vrais et faux billets dans chaque sous-ensemble.

ONCFM

Modélisation : deux approches

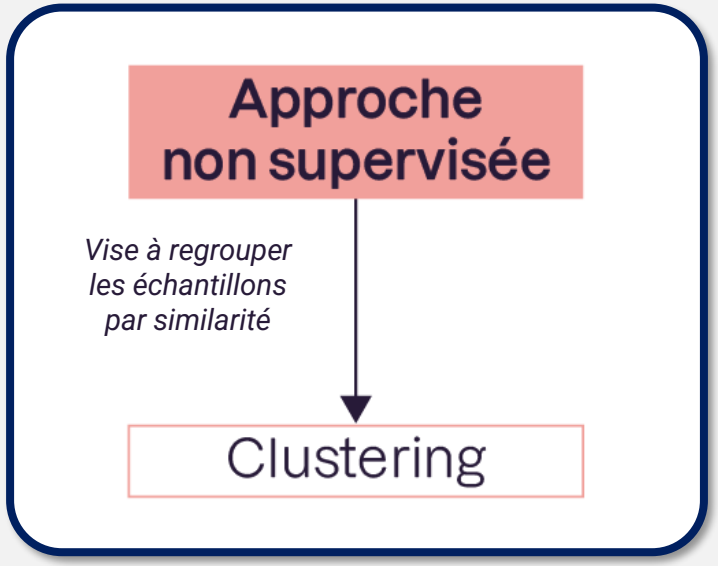

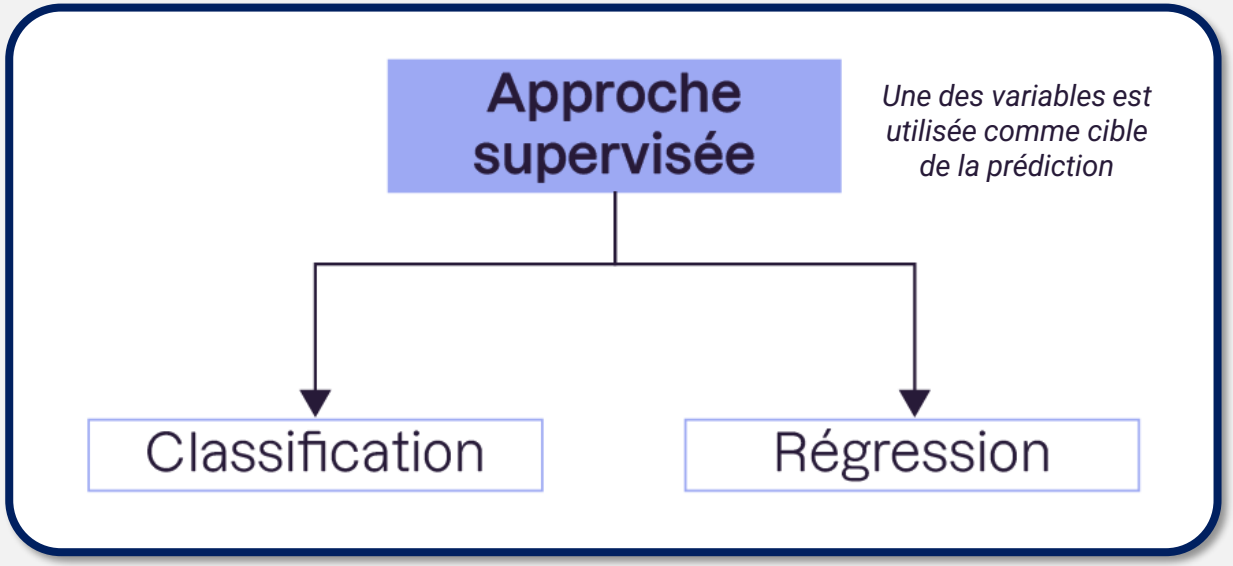

Analyse exploratoire sans utiliser la variable cible (*is_genuine*).

<u>Objectif :</u> vérifier si les billets se structurent naturellement en groupes distincts à partir de leurs caractéristiques géométriques.

Utilisation de la variable cible (*is_genuine*) pour entraîner un modèle prédictif.

<u>Objectif :</u> apprendre à distinguer les vrais billets des faux à partir des variables géométriques.

ONCFM

Clustering KMeans:
correspondance à 98 %

k = 2

	Vrais Billets	Faux Billets
Cluster 0	**98,6 %** de correspondance	1,4 %
Cluster 1	1,8 %	**98,2 %** de correspondance

Chaque cluster correspond majoritairement à une classe réelle (vrai / faux)

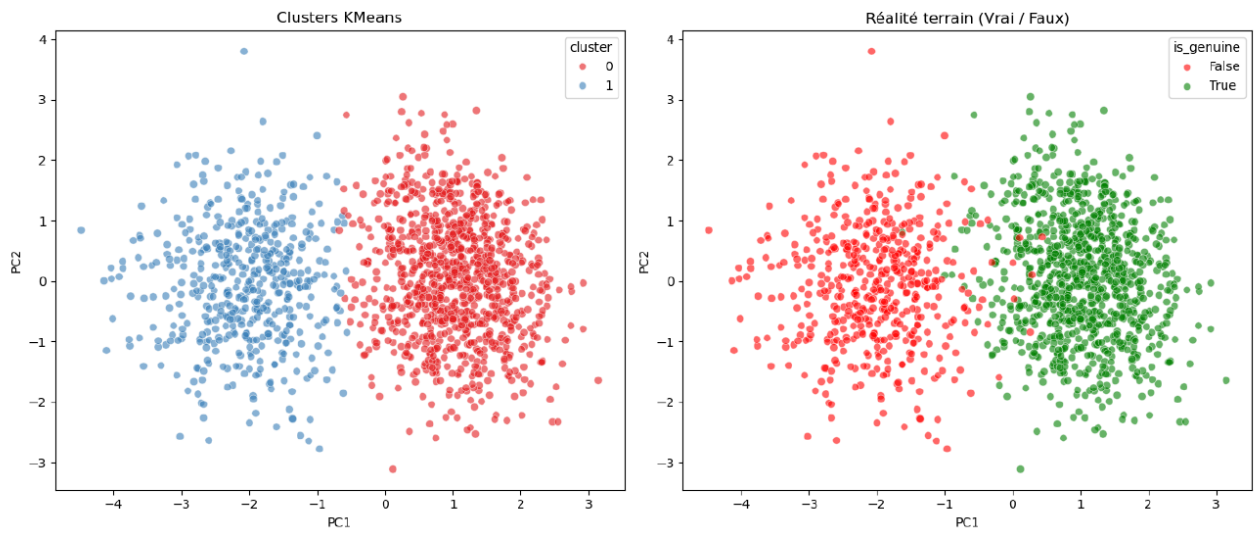

Le verdict :

- La géométrie contient une information fortement discriminante.
- Les billets se structurent naturellement en deux groupes cohérents.
- ► La modélisation supervisée est pertinente et justifiée.

ONCFM

Confrontation des modèles supervisés

Régression Logistique

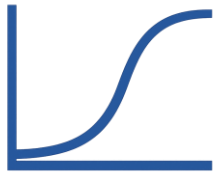

Modèle probabiliste de référence
Interprétable et robuste

KNN
(K-Nearest Neighbors)

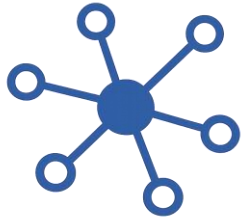

Classification par proximité
Sensible au choix de K

Random Forest

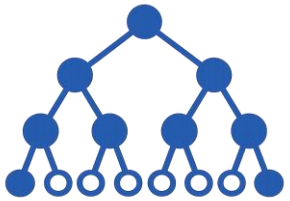

Modèle non linéaire
Agrégation d'arbres décisionnels

<u>Évaluation basée sur :</u>

- Matrice de confusion
- Accuracy
- Précision
- Rappel
- F1-score

Objectif métier : minimiser les faux négatifs
→ Ne laisser passer aucun faux billet

ONCFM

Régression Logistique

Modèle de classification linéaire estimant la probabilité qu'un billet soit authentique.

- ▶ Modèle simple et interprétable
- ▶ Sert de modèle de référence
- ▶ Fournit des probabilités exploitables

Résultats :

Accuracy : 98,63 %

Performance globale élevée, mais l'analyse détaillée du rappel sur la classe FAUX reste prioritaire.

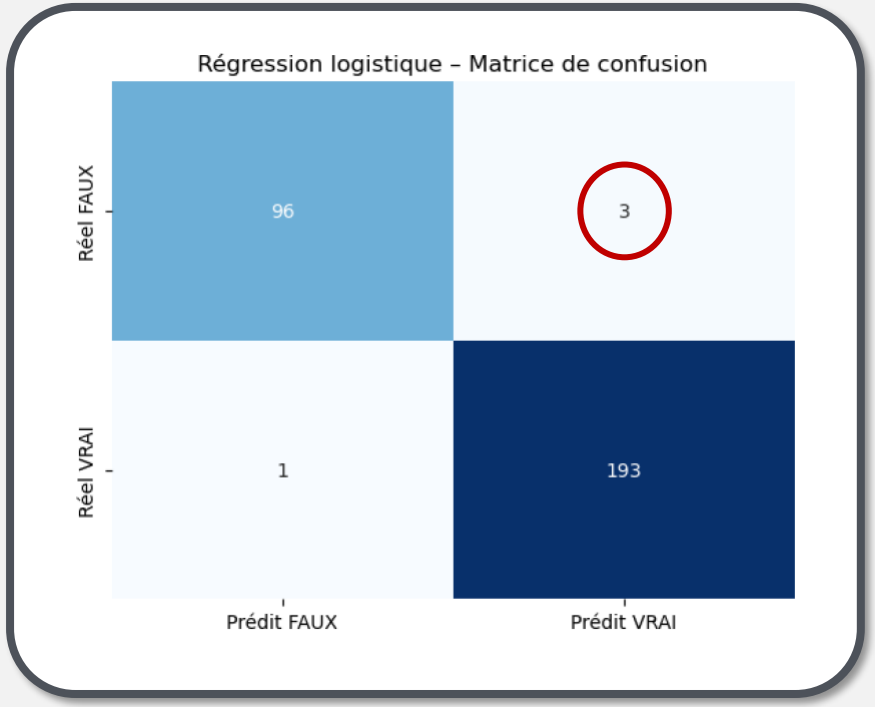

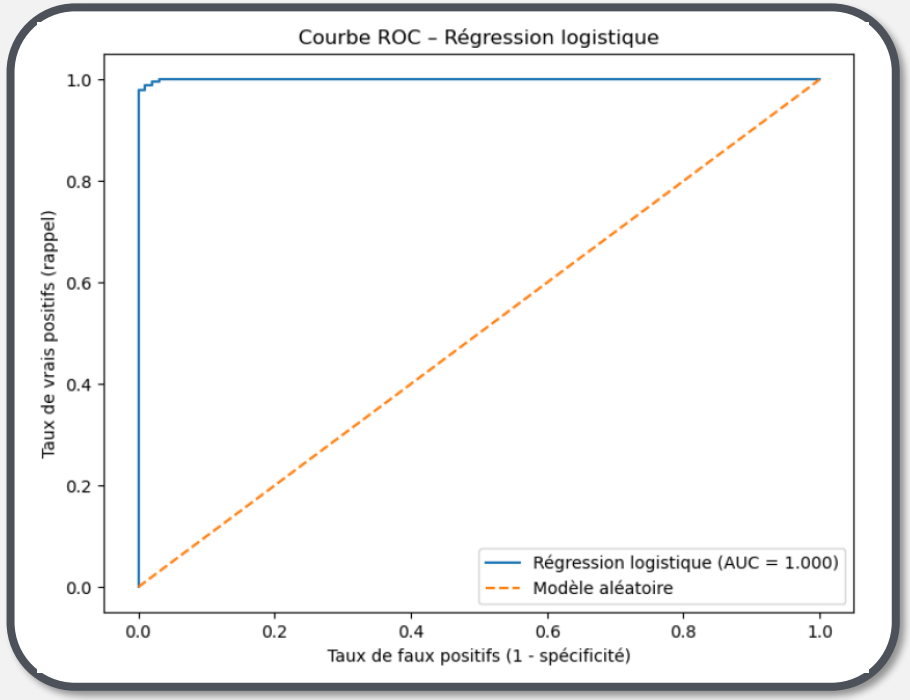

3 faux billets classés à tort comme authentiques (faux négatifs)

AUC : 0.9996

Séparation quasi parfaite des classes en termes probabilistes.

	Precision	Recall	F1-score	Support
FAUX	**0,99**	**0,97**	**0,98**	**99**
VRAI	**0,98**	**0,99**	**0,99**	**194**
Accuracy			0,99	293
macro avg	0,99	0,98	0,98	293
weighted avg	0,99	0,99	0,99	293

ONCFM

KNN
(*K-Nearest Neighbors*)

Classe un billet selon les K billets les plus proches.

- ► Méthode basée sur la distance
- ► Aucune hypothèse linéaire
- ► Sensible au choix de K

Résultats :

Accuracy : 98,97 %

Performance globale élevée, mais l'analyse détaillée du rappel sur la classe FAUX reste prioritaire.

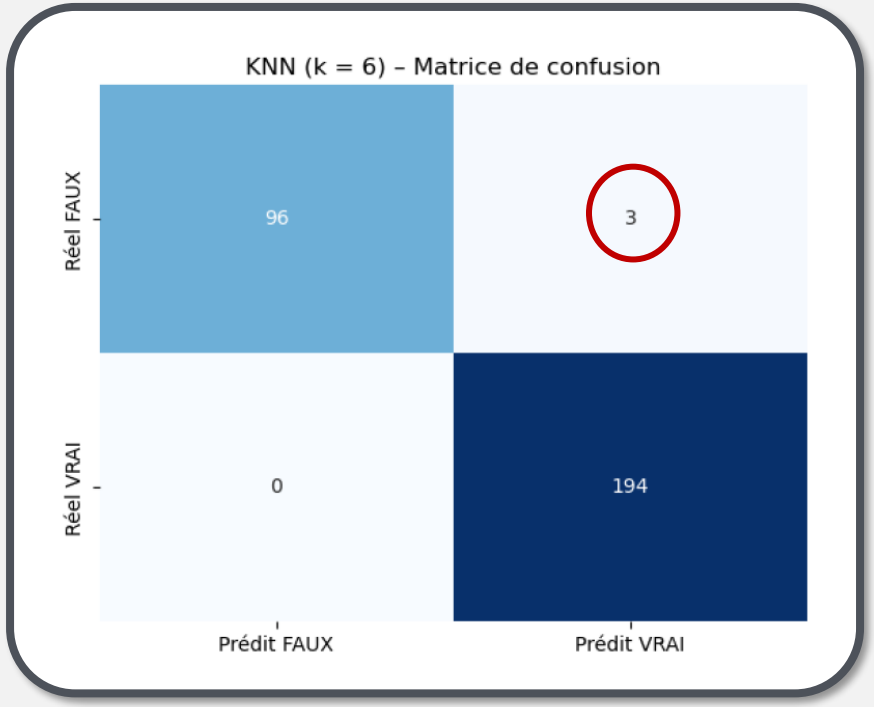

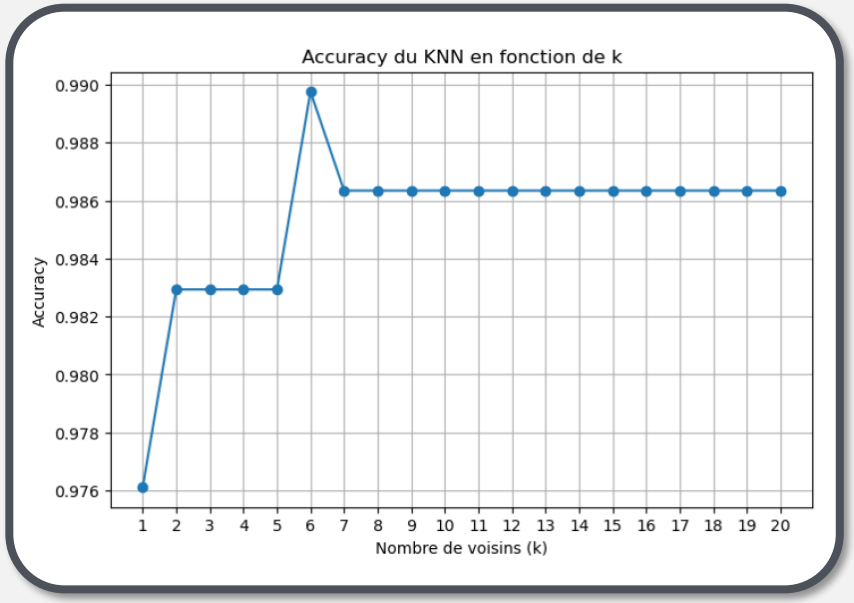

k = 6

meilleur compromis entre performance et stabilité du modèle

3 faux billets classés à tort comme authentiques (faux négatifs)

	Precision	Recall	F1-score	Support
FAUX	1,00	0,97	0,98	99
VRAI	0,98	1,00	0,99	194
Accuracy			0,99	293
macro avg	0,99	0,98	0,99	293
weighted avg	0,99	0,99	0,99	293

ONCFM

Random Forest

Ensemble d'arbres de décision combinés par vote majoritaire.

- ► Modèle non linéaire
- ► Très performant et robuste
- ► Fournit l'importance des variables

Résultats :

Accuracy : 98,97 %

Performance globale élevée, mais l'analyse détaillée du rappel sur la classe FAUX reste prioritaire.

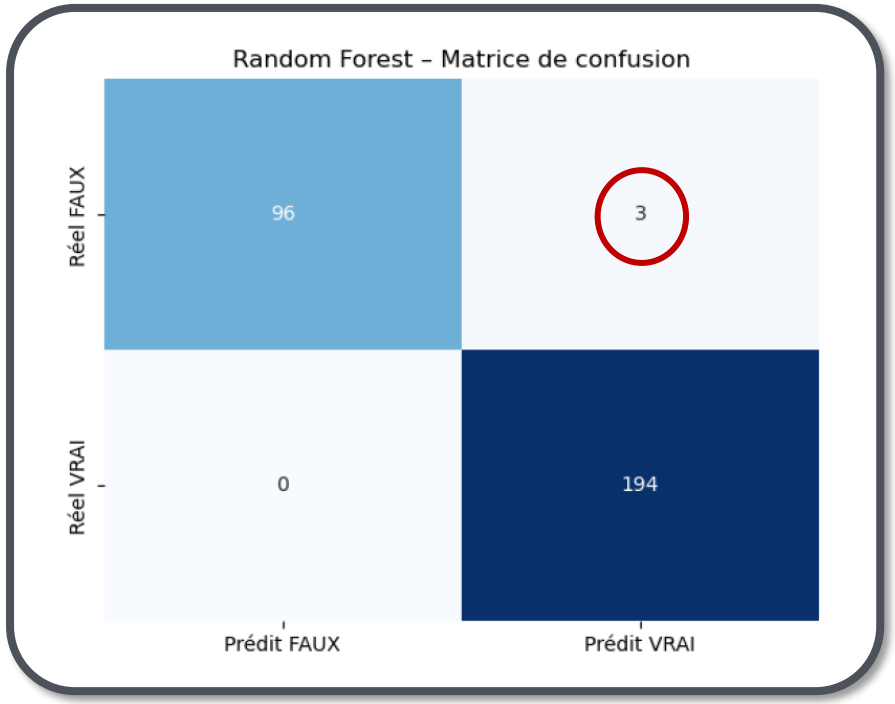

3 faux billets classés à tort comme authentiques (faux négatifs)

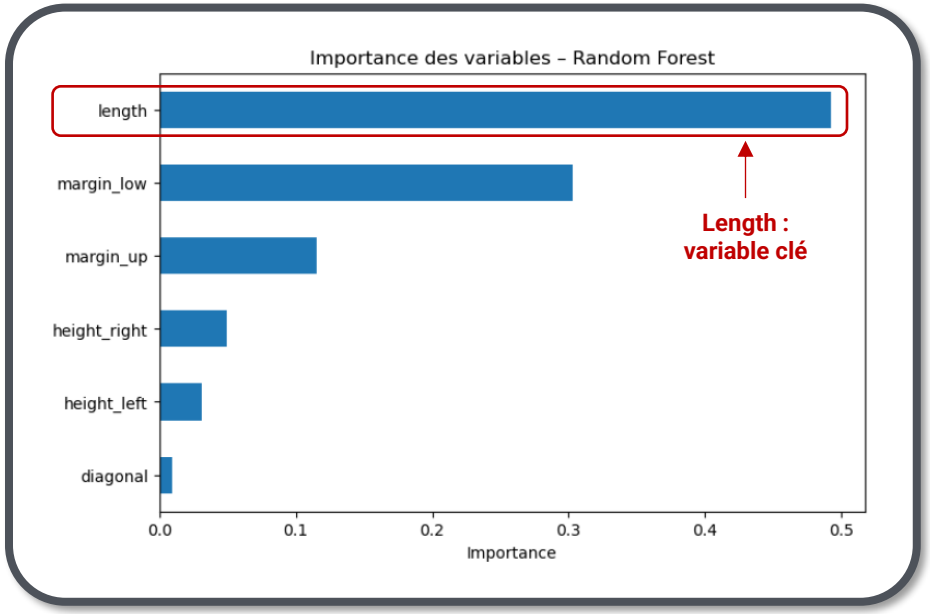

Le modèle confirme que la variable length est de loin la plus discriminante, suivie de margin_low.
La géométrie seule explique l'essentiel de la décision.

	Precision	Recall	F1-score	Support
FAUX	**1,00**	**0,97**	**0,98**	**99**
VRAI	**0,98**	**1,00**	**0,99**	**194**
Accuracy			0,99	293
macro avg	0,99	0,98	0,99	293
weighted avg	0,99	0,99	0,99	293

ONCFM

Comparaison des Performances

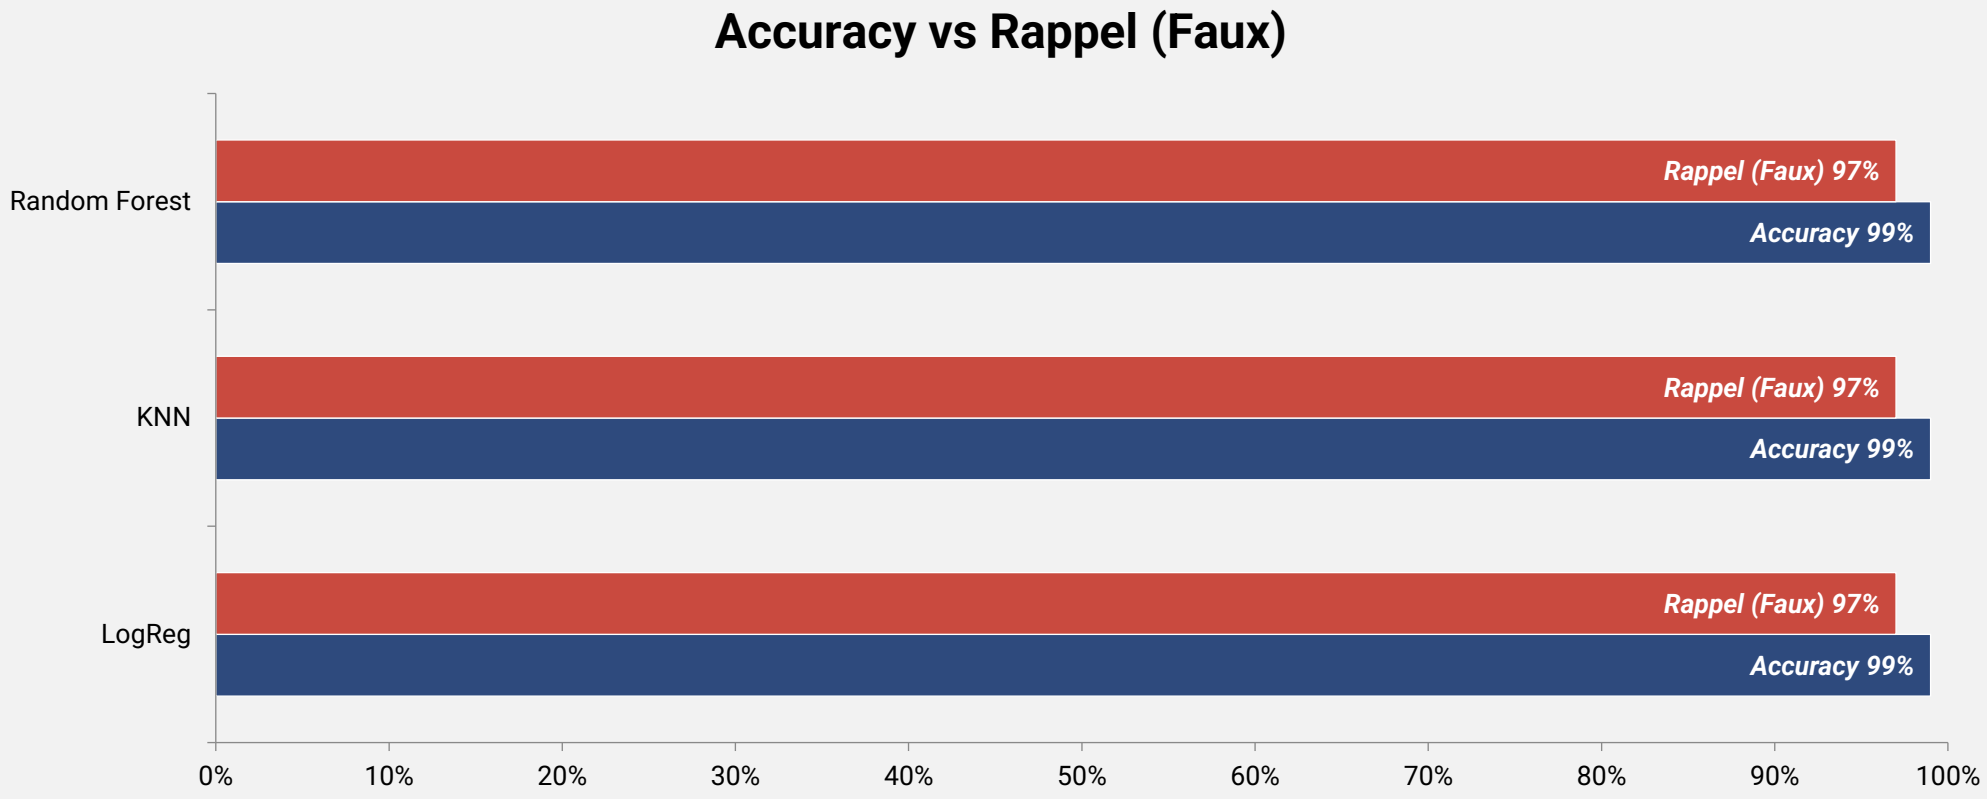

Constat :

- Performances quasi identiques (~99 % *accuracy*, 97 % *recall* FAUX)
- Les 3 modèles échouent sur les mêmes 3 faux billets
- La complexité supplémentaire n'apporte pas de gain significatif

ONCFM

Le vainqueur : Régression Logistique

Choix par principe de parcimonie (Occam).
À performance équivalente, on privilégie le modèle le plus simple.

Pourquoi ce choix alors que les scores sont égaux ?

Performance
98,6 % d'*accuracy*, équivalent aux modèles complexes

Interprétabilité
Modèle mathématique explicite. Compréhension claire des facteurs influençant la décision.

Robustesse
Moins sensible au sur-apprentissage (*overfitting*) sur un *dataset* de taille modérée.

Probabilités
Fournit un score de confiance exploitable pour l'aide à la décision opérationnelle.

ONCFM

Analyse de risques

VRAI POSITIF **96** Faux billets correctement bloqués	**FAUX NEGATIF** **3** Faux billets non détectés ► Risque principal
VRAI POSITIF **1** Vrai billet bloqué à tort ► Coût opérationnel	**VRAI NEGATIF** **193** Vrais billets validés

Sur 293 billets testés :

- ► Le modèle bloque 97 % des contrefaçons
- ► Le risque résiduel est limité à seulement 3 billets sur 99 faux.
- ► Le système est exploitable en production sous supervision.

Sur Taux de faux négatifs : 3/99 = **3 %**

Rappel (classe FAUX) : **97 %**

ONCFM

L’outil opérationnel

Déploiement du modèle retenu dans une application opérationnelle simple et utilisable par les équipes.

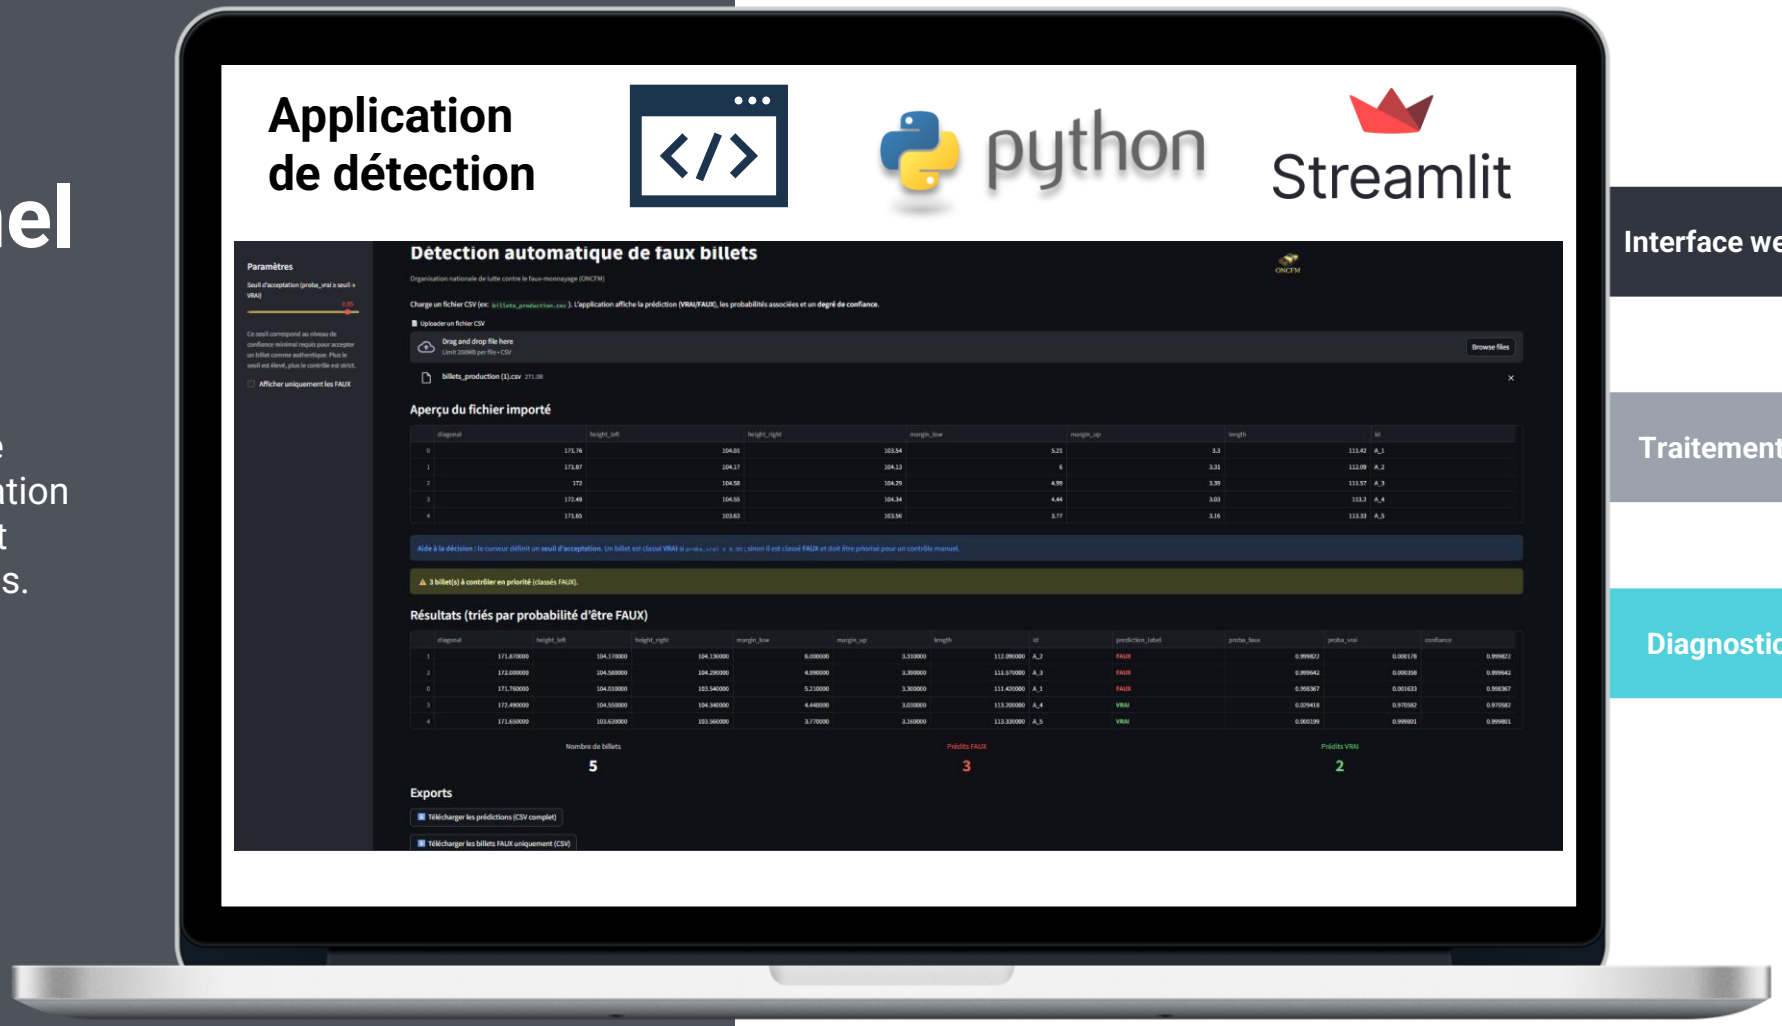

Interface web intuitive

Traitement en masse

Diagnostic immédiat

ONCFM

Conclusion et recommandations

Phase d'analyse

Analyse des caractéristiques géométriques : Validée

Qualité des données

Nettoyage et validation : Jeu de données fiabilisé

Modélisation

Modèle prédictif performant (> 98 %)

Régression logistique retenue (robuste et interprétable)

Déploiement

Application opérationnelle (Streamlit) : Disponible

Prochaine étape :
Lancement d'un pilote auprès des équipes de contrôle pour validation terrain

ONCFM

Merci
de votre attention

Démonstration de l’application

ONCFM